

Introduction to Digital History

<https://wissen-ist-acht.github.io/digitalhistory.intro/>

Ina Serif

Last compiled on 28.05.2026

Table of contents

Welcome	4
I Introduction	5
1 What is Digital History?	6
2 Teaching and Research	7
2.1 Digitised Sources, Digital Sources	8
2.2 Digital Tools for Analysis	9
2.3 Digital Tools for Communication	11
2.4 Projects and Resources for Teaching and Research	12
2.4.1 Ancient History	12
2.4.2 Middle Ages and Early Modern History	12
2.4.3 Modern and Contemporary History	13
2.4.4 Jewish History	14
2.4.5 African History	14
2.4.6 Eastern European History	15
2.4.7 Supra-national and Trans-epochal History	15
3 Digital Literacy, Digital Criticism	16
3.1 Digital Literacy, Data Literacy	16
3.2 Digital Criticism, Data Criticism	16
3.3 Artificial Intelligence and Algorithm Criticism	22
4 Data Gathering, Data Processing, Data Analysis	24
4.1 Data Gathering	25
4.2 Data Processing	28
4.3 Data Analysis	29
4.4 Data Storage	31
5 FAIR, CARE and LOUD	32
5.1 FAIR Data	32
5.2 CARE Principles	33
5.3 LO(U)D	33

II Practical Section	35
Hands on	36
6 ‘Der Sturm’ – Edited Correspondence	37
7 Through the Front Door	40
8 Through the Back Door	41
8.1 Shell 101	42
8.2 Ctrl-F 2.0	43
8.3 First Steps	47
9 Perspectives	53
 Appendices	 58
A Glossary	58
Glossary	58
B Literature, Tools, Tutorials	59
B.1 What is digital history?	59
B.2 Introductions and Guides	59
B.3 Digital History Tools (free/open source)	60
B.3.1 General	60
B.3.2 Data Analysis	60
B.3.3 Maps	60
B.3.4 Network Analysis	61
B.3.5 Text/Corpus Analysis	61
B.3.6 Storytelling	61
B.3.7 Visualisation	61
B.4 Digital Literacy, Digital Criticism	62
B.5 Programming Languages & Editors	62
B.6 Regular Expressions	63
B.7 Terminal/Command Line/Shell	63
B.8 XML	63

Welcome

The following guide, created during the autumn semester of 2022, is intended for first-year students of [History at the University of Basel](#) and gives first insights into the subject of Digital History. It is a living document that will be regularly updated and it means to take into account the different epochal and areal foci of the different introductory courses by adding more and more Digital History projects from throughout the field over time. For the participants of the introductory course, the guide will be accompanied by an in-person meeting, but it can hopefully also be used independently. I am happy to receive [comments, suggestions or complaints](#).

The guide is made up of two parts: Chapters one to five give an initial overview of Digital History and the changes that digital methods have brought to the field of historical studies. The ensuing practical part uses a concrete example in order to show the application of different techniques that can be used by (not only) historians working with source material. This part has two aims. Firstly it is intended to reduce people's shyness when using the computer as something other than simply an electronic typewriter. Secondly it wants to create a basic understanding of what possibilities computer assisted analyses have to offer and how to implement these in historical research.

The overview is as brief as possible – there are numerous detailed handbooks, for which reason many themes are only touched upon briefly and I give references to further literature. The same goes for the practical part: links are given to tutorials, online courses and further instructions when applicable. These references are by no means complete and I am happy to include your suggestions for further online resources.

Part I

Introduction

1 What is Digital History?

There is endless possibility for discussing what the right answer to the question of what the term Digital History can encompass is. Since it is a part of the Digital Humanities, the current pragmatic definition by Blaney et. al (2021) can be useful:

Digital humanities, in our view, is a question of approach: if you are actively and critically using digital tools to aid your work in researching, teaching or learning, you are probably doing digital humanities. We would encourage anyone to learn to program if they are interested in doing so, but we do not see it as a defining characteristic of work in digital humanities. [1, S. 6]

“Digital tools” can mean a whole lot of different things, and you will hardly be able to find anyone who completely abstains from using any of these in their studies, in research or in teaching. We are all as historians living in a digital age and as such need to develop new competencies. We use word processing programmes as a matter of course for our seminar papers or essays, research via search engines and online catalogues or lexica are part of the daily business of historians. But in addition to that we can decide to use methods and techniques for a research project that go beyond the tradition tools of the historians – the analysis and interpretation of sources through [close reading](#) – and let ourselves be helped by the computer. Whether we do this with the help of existing software or write our own programmes, understanding ourselves not only as historians of a digital age but also as digital historians may for some be a matter of principle; an inclusionary attitude towards this question however seems to me to be only beneficiary.[Quite opposed to a frequently cited opinion of Emmanuel Le Roy Ladurie’s (*1929) the historian of tomorrow shall either be a programmer or not be at all: “l’historien de demain sera un programmeur ou il ne sera pas.” [5](#)]

For a first idea of how one can answer historiographical questions with the help of digital methods and how diverse digitally assisted research projects can look like, take a look at the article “[State of the Field: Digital History](#)”.[9]

A growing list of examples from different epochs and thematic fields can be found in chapter two under Projects and Resources.

This guide is about an active, critical and reflected use of digital methods in teaching and research, with a focus on the uses for historians. Further reading on the question of what Digital History is as a whole can be found under Literature, Tools, Tutorials

2 Teaching and Research

The way that, in all walks of life, things are becoming more and more digitised has a number of different consequences for historical studies, on many levels: when it comes to research and the work with sources, using digital methods not only for analysis but also for communication, and finally for teaching in higher education.



Figure 2.1: Randall Munroe, History Department, xkcd.com (17.12.2018).

2.1 Digitised Sources, Digital Sources

As historians, sources are central to our analyses. That means that access and availability of documents has a great influence on what questions we are able to answer or which analyses we can undertake. Restrictions as to access, which can influence the size and quality of our corpus, can be set by institutions such as museums, archives and libraries, for instance when contemporary documents are protected for a period of time, or an object is too fragile for use. It can also be difficult for financial or organisational reasons to access archives further away, in order to be able to include more documents in one's analysis. Large-scale digitisation project

in libraries and archives thus offer the possibility of finding additional material not just as a catalogue entry but as actual digitised copies that one can download onto one's own computer. Especially for valuable historical objects – such as antique papyri, early medieval manuscripts, early printed documents etc – this offers a possibility of making the objects available to a far larger audience without the strain of continuous usage, and without the users having to take long journeys to see them. For medieval manuscripts and early modern manuscripts and prints for instance there are nowadays many (mostly national) portals that allow a central search of all collections; you will find a selection in [Section 2.4.2](#).

Next to the digitisation of existing sources (retro digitisation) we have the unstoppable production of new sources purely in digital form (born digital data). The relative scarcity of sources often bemoaned by scholars of premodern history is in opposition to the surfeit of contemporary material. Both situations – too little, too incomplete and too much, too confusing – come with methodological difficulties: How does one put together a corpus (a collection) of sources that contains sufficient documents to allow one to answer questions, underline theses and gain new insights, but still remains manageable? Historians need to acquire new competencies in order to deal with such questions: in addition to the classic source critical analysis we now need digital source criticism, in addition to the ability to read and understand analogue sources, the ability to do the same for the digital realm. More about digital literacy and digital criticism in [chapter 3](#).

2.2 Digital Tools for Analysis

The definition already cited [here](#) that it is the active critical use of digital tools in teaching, research and study which makes up the Digital Humanities, begs the question of what exactly we mean by digital tools and to what ends we use them. Even reading this guide without digital methods is not possible – it does not exist in printed form. Reading at the screen does not make you a *digital humanist*, but one does not need to learn programming to be able to use the computer for one's own work and to achieve results that would not have been possible in the same measure with classical methods – in history mainly paper-based *close reading* of sources and scholarly texts.

Research that uses digital methods is usually scalable – if one is using software that counts the frequency of terms in one document, it should not make a difference to the software whether it does this with one or with one hundred documents. If you do this by hand however, the amount of analysis grows in proportion to the amount of documents. So digital tools allow us, amongst other things, to ask the same question of a far larger corpus of sources. It also allows us to ask different questions of this large corpus than would be possible with a small one. In the main, historical sources are text-based. Written by hand, carved, or printed – and with the possibility of changing this text via text recognition software into data that is readable to

a computer, sources can be turned into data that is able to be examined and analysed with the help of quantitative methods.¹

For Literary studies, for instance, one important field of use is to check for authorship. Whether an anonymous text can be attributed to a known author can either be judged by a literary scholar through *close reading* of the text, or through the search for patterns, for quantifiable attributes of a text, such as the frequency of function words, particles, punctuation etc. The detective novel *The Cuckoo's Calling*, published under the pseudonym of Robert Galbraith, could be attributed to Joanne K. Rowling by the relevant software – and this in thirty minutes, about as much time as it takes to read twenty pages of the novel. [Here](#) you can read an article that deals with this case and situates it within the field of linguistic forensics, which investigates offenders with the help of quantitative text analysis.

A video about the development and use of software for authorship attribution can be found [here](#). The software used, JGGAP,² can obviously also be used for historical analysis – think of regimes with strict censorship and numerous authors not publishing under their real names. By identifying anonymous writers different themes connected with censorship can be studied: which authors were publicly recognised, who at the same time published anonymously and under their real names, which authors wrote in exile, what networks can be reconstructed, etc. Having a programme that *can* do the quantitative analysis and thus the main job of identification (on how to think carefully about data and algorithms, see [chapter 3](#) –, means that there is more time remaining for the qualitative analysis. At the same time the analysis is based on a significant amount of data instead of looking just at individual cases.

The idea is not to play off qualitative and quantitative methods against each other, rather show that both methods have positive and negative aspects and that in the best case they can be used to good advantage in combination. Quantitative analysis just for the sake of it and without specific historical question is hardly ever of added value.

Depending on the data base, analytical purpose and research question, there are different tools you can use. For most of the research you will be doing during your studies, existing software should be sufficient, be it for statistical analysis, network analysis, geomapping or visualisation. You can find a selection of tools (all free of charge / open source) under the heading Literature, Tools, Tutorials. For certain analyses it can be helpful to learn some basic programming skills – being able to write your own scripts (smaller programmes) means having full control over the way in which data is read, prepared, enriched, analysed and visualised; with repeated processes that take a lot of time when doing them by hand, a lot of time can be saved.

For projects in the humanities there are at the moment two programming languages mainly being used, [R](#) and [Python](#). Since both are popular in the humanities you can nowadays find numerous packages that make data and text mining (large-scale data and text analyses) very easy. Such packages for programming languages are like plug-ins for programmes, for instance

¹This is easier to do for contemporary history, as many texts are already extant in digital form, for those periods or fields that are generally less rich in sources, generating data from text can nevertheless be even more interesting.

²Java Graphical Authorship Attribution Program, <http://evllabs.github.io/JGAAP/>.

like an ad blocker for the browser. These were not originally intended by the developers, but someone wanted to block advertisements and wrote a programme to do so, making it free for the general public to use. The difference in a package is that a package offers numerous different functions that the users can then choose and implement. Who has not had any contact with programming in school and university may possibly have some trepidation at first, but once again: you do not need to be able to programme in order to do quantitative work. There is a project called “[The Programming Historian](#)”, which has offered numerous tutorials since 2008 for historians without previous programming experience, introducing different tools, techniques and workflows for historical research and teaching.

2.3 Digital Tools for Communication

Even without quantitative/computer based analyses there are various options in historical research to use digital methods to assist in communicating results. These are on the one hand different types of digital publishing and on the other the use of digital tools to visualise results. Printed academic journals and publishers have certain criteria for accepting texts for publication – content quality is important for any academic work, but formal criteria such as length/imaging etc. are less central for online formats. In this way first results from a new research project or even a seminar paper can be offered up to an interested audience in the form of a blog article without much organisational preparation or regard for a publisher’s workload.

The number of academic blogs has been rising continuously in recent years, so that there are a number of suitable publication options available for every possible subject. These are edited, meaning that they are in the hands of academics who see themselves as responsible for the quality of the contributions. PhD projects are also often accompanied by blogs – giving visibility to the research and offering a space for themes that have no room in the actual dissertation, but are still noteworthy.

[Hypothèses](#) has established itself as an important platform that hosts a number of academic blogs. You can find a catalogue of all the blogs [here](#), and you can filter according to subject and period. The following blogs are the result of research and teaching at the History Department of the University of Basel:

- [Exilland Schweiz](#). Kulturschaffende und Intellektuelle im Schweizer Exil, 2021–
- [Global Health Africa](#). Circulating Knowledge and Innovations, 2019–
- [Materialized Histories](#). Materielle Kultur und digitale Forschung, 2021–
- [Materialized Identities](#). Objects, Affects and Effects in Early Modern Culture (1450–1750), 2016–2021.

- [Stadt.Geschichte.Basel](#). Blog zum Forschungsprojekt, 2019–
- [The Color Line](#). Race Relations in Schlüsseltexten amerikanischer Autor:innen (1881–1953), 2022–

A relatively recent format are Data Stories – narratives that describe a situation on the basis of (quantitative or qualitative) data and analyses. This type of (data) publication is used especially in journalism, and helps to ensure interactivity and actuality of data. There are various tools that can be used to create such data stories, some of them include publication possibilities; there is a selection under Literature, Tools, Tutorials.

One example that allows the users to add content themselves is [Darüber spricht der Bundestag](#), a Data Story by the newspaper “DIE ZEIT”, which allows analysis of all the speeches given in the German Bundestag since 1949. An example for a map-centric depiction that embeds various different media is [Arya’s Journey](#) from *Game of Thrones*. An example for the use of public census data is by the Schweizer Bundesamt für Statistik, [Die Schweiz \(er\)zählen](#).

2.4 Projects and Resources for Teaching and Research

2.4.1 Ancient History

Projects:

- [D-Scribes](#): Project recognising ancient authors of Greek and Coptic papyri

Resources/portals:

- [Papyrus Portal](#): digital collection of papyri
- [The Arabic Papyrology Database](#): Data base of premodern arabic texts written on papyri, parchment or paper from the 7th to the 16th century

2.4.2 Middle Ages and Early Modern History

Projects:

- [Burchards Dekret Digital](#): Digital edition analysing the manuscript transmission of the Decretum Burchardi
- [République des Lettres](#): Edition and research platform with numerous collections of texts by scholars between 1700 and 1850, connected to structural data
- [Printed Markets](#): Project digitising and commenting on the early modern “Avisblatt” from Basel (1729–1844)

- [Repertorium Academicum](#): Project compiling data on european scholars between 1250 and 1550

Resources/portals:

- [dMGH](#): Monumenta Germaniae Historica online (Beta-Version)
- [e-codices](#): Virtual Manuscript library of Switzerland
- [Fragmentarium](#): Laboratory for Medieval Manuscript Fragments
- [Handschriftenportal](#): Central national register of book manuscripts in German libraries and in German language (in development)
- [Innovating Knowledge](#): Data base and digital edition of Isidor of Sevilla’s “Etymologiae”
- [e-manuscripta](#): Digitised manuscripts from Swiss libraries and archives
- [e-rara](#): Platform for digitised prints from Swiss Institutions
- [Gallica](#): Digitised sources from French libraries
- [Stapfer Enquête](#): Edition of a Swiss school census from 1799
- [swisscollections](#): search platform for historical Swiss collections
- [transcriptiones](#): platform for the creation, sharing and use of transcriptions of historical manuscripts

2.4.3 Modern and Contemporary History

Projects:

- [impresso. Media Monitoring of the Past](#): project for the processing, semantic editing, representation, exploration and research of data in historical media (newspapers and radio), across time, languages and national borders
- [Living with Machines](#): research project on the impact of the mechanisation of work during the industrialisation.
- [Refugee History](#): academic blog and interactive network on the current debates around “refugees”

Resources/portals:

- [Datenbank Bild + Ton](#): on the history of Swiss social movements
- [Dodis](#): historical editions of documents on Swiss foreign affairs
- [Gallica](#): digitised sources from French libraries

- e-newspaperarchives.ch: Schweizer Zeitungen online
- [e-periodica](http://e-periodica.ch): Swiss newspapers online
- [Historische Statistik der Schweiz](http://historische-statistik-der-schweiz.ch) (HSSO): historical statistic of Switzerland
- [histat](http://histat.ch): historical statistics

2.4.4 Jewish History

Projects:

- [Digital Jewish Studies Online](http://digitaljewishstudies.org), Stroum Center for Jewish Studies, University of Washington

Resources/portals:

- [Blavatnik Archive](http://blavatnikarchive.org): archive for the preservation of material on jewish history of the 20th century with a focus on the world wars and soviet Russia
- Menny, Anna; Rürup, Miriam; Siegel, Björn: Jüdische Geschichte im deutschsprachigen Raum, in: Busse, Laura u. a. (Hg.): Clio-Guide. Ein Handbuch zu digitalen Ressourcen für die Geschichtswissenschaften, Berlin 2018, S. E.2-1–E.2-56. Online: <https://doi.org/10.18452/19244>.

2.4.5 African History

Projects:

- [Emandulo](http://emandulo.org): Digital archive that brings together and curates archival/museal collections and presentations on precolonial South African history
- [Legacies of British Slavery](http://legaciesofbritishslavery.org): research project on the British slave trade and ownership

Resources/portals:

- [FHYA](http://fhya.org): Experimental digital research platform on precolonial South African history
- [Legacies of British Slavery](http://legaciesofbritishslavery.org): data base on British Slave trade and ownership
- [Slave Voyages](http://slavevoyages.org): data bases on the transatlantic and interamerican slave trade with a data base of individuals

2.4.6 Eastern European History

Projects:

- [Gulag: Many Days, Many Lives](#): Archive and presentation on sovjet gulags
- [Gulag Online](#): virtual museum with presentations and sources on life in the gulag
- [Seventeen Moments in Soviet History](#): multimedia online archive with selected sources on events in soviet history based around 17 different years between 1917 and 1991
- [The Imperiia Project](#): a spatial history of the Russian Empire

Resources/portals:

- [Blavatnik Archive](#): archive for the preservation of material on jewish history of the 20th century with a focus on the world wars and soviet Russia
- [The Other Side](#): Web archive with interviews of ex-Ostarbeiter, POWs and inmates of German camps. Publication platform

2.4.7 Supra-national and Trans-epochal History

Projects:

- [Lord of the Rings Project](#): interactive analysis of the work of JRR Tolkien

Resources/portals:

- [Around DH in 80 days](#): portal presenting 80 different Digital-Humanities- Projects world-wide and from various disciplines
- [Internet Archive](#): digital library archiving books, images, films, software, music and websites

3 Digital Literacy, Digital Criticism

3.1 Digital Literacy, Data Literacy

What we understand by Data Literacy is the competence to collect, manage, evaluate and use data,[7, p. 8] a competence everyone should develop for themselves in order to deal with all the various forms of data we encounter in everyday life nowadays. Depending on the discipline there are differences in the specific competencies necessary – a humanities student may not think that algorithm criticism is the most important thing to learn when starting to study.¹ But you do not need to understand every detail of machine learning software’s source code in order to have a basic understanding of the way such applications function, and to be able to reflect on their usage. This kind of digital or data literacy is relevant especially when it comes to interpreting results that appear to be objective, or to have been produced without bias. A good example are the results of a query in a search engine. Depending on which engine you are using, different circumstances will play into generating your results list. For instance your own search history, meaning that *search neutrality* is no longer a given.² Go to [Google Image Search](#) and search for “historian”. What do you see?

If I did not know anything about historians, the results of my search would lead me to believe that a historian is an old, white man with glasses, a beard, and a large bookshelf. If you look around at the History Department in Basel, you might get a rather different impression. The results of search engines, that use algorithms in order to function, are biased: They are based on previous searches, preferences, geographical location – and on metadata offered by humans, data with information about other data. It is part of working in a digitised world that we are aware of this, and know to question data.

3.2 Digital Criticism, Data Criticism

Digitised Sources, just like purely digital ones, need advanced source criticism – in the introductory course at the University of Basel you will learn the basics of classic source criticism:

¹Different organisations and interest groups have thought about this, and the German “Gesellschaft für Informatik” has published a white paper on Data Literacy and Data Science Education as a digital competence in higher education: https://gi.de/fileadmin/GI/Hauptseite/Aktuelles/Aktionen/Data_Literacy/GI_Data_Science_2018-04-20_FINAL.pdf.

²There are alternative search engines, such as [Startpage](#) or [DuckDuckGo](#).

Where does a source come from, who has created it under what circumstances? What objectives could have been behind the creation, what biases could be in the text due to the circumstances of its creation? What can you read in a high-medieval king's chronicle, if the author was directly dependent on the person commissioning the work? How do we read the witness statements of an inquisition into witchcraft, if they were gathered under threat of torture? How carefully do we need to analyse the contents of a diary that was written with a view to later publication?

Apart from the internal criticism, working with sources always also concerns the question of the creation of corpora: what constitutes a significant corpus of sources that can be used for a specific historical question, but at the same time can be analysed in a manageable amount of time? Additionally, different types of sources bring different difficulties: With analogue sources that are also available in digitised form, there is the danger that a subject, area or aspect is neglected if only the immediately accessible, digitised collections are used. If for instance you are interested in the Swiss historian and women's rights advocate [Meta von Salis](#) (1855–1929) and her correspondence – Friedrich Nietzsche was one of her correspondents – and you go on to the catalogue [swisscollections](#), the search engine for Swiss historical collections, to look for the relevant documents in national libraries and archives, you will get 361 hits. :: {layout="[49,-2,49]"}

← Einfache Suche

Erweiterte Suche

Mit Allen Wörtern (AND)

meta von salis

Alle Felder



Alle Felder



Alle Felder



+ Suchfeld hinzufügen

+ Suchgruppe hinzufügen

Suchen

Suchtipps

[Hilfe zur erweiterten Suche](#)

[Hilfe zu den Suchoperatoren](#)

Suche verfeinern

Sprache

Sprachen suchen

Format

Brief ✕

Bibliothek

Bibliotheken suchen

Jahr

von:

bis:

300

2023



Treffer pro Seite

20

Suchen

361 Suchergebnisse für: (Alle Felder:meta von salis)

Seite: ← 1 von 19 →

Sortieren nach Relevanz ▼

☐ Digitalisat verfügbar



Brief an Meta von Salis-Marschlins
von Louise von Schwerin
 Schwerin, Louise von
 1909.06.22
 Basel, UB, UBH NL 61 : M. IX 25



Brief an Meta von Salis-Marschlins
von Emmy von Strössenreuter
 Strössenreuter, Emmy von
 1918.12.27
 Basel, UB, UBH NL 61 : S. III IV 188



Brief an Meta von Salis-Marschlins
von Bertha von Cramer
 Cramer, Bertha von
 1867.04.19
 Basel, UB, UBH NL 61 : M I A 2a



Brief an Meta von Salis-Marschlins
von Anton von Salis
 Salis, Anton von
 1915.01.23
 Basel, UB, UBH NL 61 : S. III IV 31

Ressourcentyp ^

- + ☐ Archivmaterial (361) X
- + ☐ Handschrift (361) X

Bibliothek ^

- ☐ Basel, UB (355) X
- ☐ Zürich, ZB, Handschriftenabteilung (6) X

Person / Körperschaft ^

- + ☐ Salis-Marschlins, Meta von ... (356) X
- + ☐ Nietzsche, Friedrich (1844-19... (15) X
- + ☐ Kym, Hedwig (1860-1949) (5) X
- + ☐ Eschmann, Marie (3) X
- + ☐ Hauser, Johann (1853-1921) (3) X

mehr

Sprache ^

- ☐ Deutsch (356) X

Schlagwörter ^

- ☐ Ravenna, Bürgermeisteramt (1) X

...

Of these, only three entries were available digitally in October 2022, of which the first was one letter of Nietzsche's to Meta von Salis, the second seven letters by Caroline Farner, and the third entry is neither by nor to Meta von Salis, but simply mentions her:

Stichwortsuche Indexsuche Durchstöbern Archivtektonik Bibliographien

swisscollections


Erweiterte Suche bearbeiten Neue erweiterte Suche starten Neue einfache Suche starten

Digitalisat verfügbar X Format Brief X

3 Suchergebnisse für: (Alle Felder:meta von salis)

Seite: ← 1 von 1 → Sortieren nach Relevanz

☒ Digitalisat verfügbar

 Brief an Meta von Salis-Marschlins von Friedrich Nietzsche Nietzsche, Friedrich 1887.09.01-14 Basel, UB, UBH NL 61 : N. II 10 IV	Ressourcentyp + ☐ Archivmaterial (3) X + ☐ Handschrift (3) X
 7 Briefe an Meta von Salis-Marschlins von Caroline Farner Farner, Karoline 1893.05.19-1895.04.07 Basel, UB, UBH NL 61 : S. II C. 2 1a-1b u.a.	Bibliothek ☐ Basel, UB (3) X
 Brief an Prof. Dr. Richard Oehler von der Universitätsbibliothek Basel Universitätsbibliothek Basel 25. Mai 1937 Dokument=Item=Pièce Basel, UB, UBH NL 53 : B III 1, Beil. 3	Person / Körperschaft + ☐ Salis-Marschlins, Meta von (18... (2) X + ☐ Farner, Karoline (1842-1913) (1) X + ☐ Nietzsche, Friedrich (1844-1900) (1) X + ☐ Oehler, Richard (1878-1948) (1) X + ☐ Universitätsbibliothek Basel (1) X
	Sprache ☐ Deutsch (3) X
	Ort ☐ Basel (1) X

Seite: ← 1 von 1 →

Figure 3.1: Search results for “Meta von Salis” + “Brief” + “Digitalisat verfügbar”

So had you attempted to create your source corpus from the comfort of your desk, only taking into account digitised sources, you would have missed most of the relevant material and the results of your analysis would have been badly skewed, had you tried to make statistical pronouncements: Meta von Salis corresponded with one man and one woman, so the gender

ratio would have been equal – but more women on average wrote to Meta von Salis than men. Looking at all the search results, your analysis would have been quite different, so it would be a good idea to eliminate this bias from your data basis.

In addition to this there is always of course the basic problem when looking for sources: swisscollections and similar portals can always only show you what their cooperational partners have made available. If a library has letters by Meta von Salis in their collections, but have not yet recorded them as a data set, you probably would not even realise – contrary to the above example – that you have missed something, that there is a bias in your corpus.

Similar caution in order to avoid bias in your data basis is necessary with purely virtual data, for instance when evaluating data sets from questionnaires. If you stand in front of the University Library in Basel on the 27th of October 2022, and for a whole day, with the help of a short questionnaire and a spreadsheet, record how satisfied those you question are with the food in the university cafeteria, you will get a data set in which probably over 80% of those questioned would like better and cheaper food – which would make a good headline for the BZ, which could then claim to be reporting based on the newest scientific research. If you repeat the experiment a week later, during the autumn fair, the results will probably look very different. The probability that the cafeteria will have revised their menu and lowered their prices within days as a reaction to the headlines in the BZ is presumably less likely than that your sample, your choice of data points, meaning the people you questioned, have changed significantly due to the fair: You will in the second time round not have met mainly students and university staff, but also people visiting the fair on the Petersplatz. Here too, we have evidence of skewed results, similar to the last example with the correspondence: If out of a total only a specific subquantity with one common trait is regarded – digitised sources or visitors of the university library – the data basis and with it your research result is biased. In order not to transmit existing biases that may be inherent in the data you are using, you need to practice data criticism.

There is a good interview with Roopika Risam (2020) on the fact that data is not simply “given” (lat. dare, datum: give, given), but created, and for that reason needs to be interpreted;[8] on the cementing of clichés by translation algorithms there is an article in the Republik by Marie-José Kolly and Simon Schmid (2021);[4] and on the power of data science and the potential for change through data feminism there is an entire book by Catherine D’Ignazio and Lauren F. Klein (2020).[3]

On the question of how the digital turn influences source criticism, watch this short video from the [Ranke.2 project – Quellenkritik im digitalen Zeitalter](#):³

A handout concerning the use of digitised and digital data that has been developed in the same project can be found [here](#).

³You find a self-study course on the subject here: <https://ranke2.uni.lu/u/archival-digital-turn/>.

3.3 Artificial Intelligence and Algorithm Criticism

With the release of ChatGPT-3 by the firm Open AI in the winter of 2022, the use of artificial intelligence (AI) all of a sudden stood open to a very large number of people. A chatbot can, after an initial registration via an [URL](#), answer all kinds of different questions, can explain Fermat's last theorem, produce sonnets in the style of Shakespeare about an Emmentaler cheese being in love with a paper clip, or can summarise the so-called Historiker:innenstreit – a dispute about the singularity of the holocaust that took place in universities in the 1980s in Germany. Technically, ChatGPT is a generative language model (generative pre-trained transformer), a so-called large language model (LLM), that has been trained with a very large data set – around one trillion words from six million Wikipedia articles, millions of websites and digitised books, all in all about 570 GB, in order to produce new text in answer to user requests.⁴ If you ask ChatGPT itself to explain the concept of a generative language model and its own algorithm, you get the following answer:

Hello! I am happy to explain the concept of generative language models and my algorithm. A generative language model is an artificial intelligence-algorithm which is trained to create texts in a specific language or style. The model uses a statistical method called probability distribution in order to judge the probability as to where a specific word or phrase will be placed in a sentence. The aim of the algorithm is to generate texts with natural speech structures and patterns, in order to be understandable and legible to humans. A generative language model can use different approaches, such as the use of recurrent neuronal networks (RNN) or transformer models. As ChatGPT, I am based on the GPT-3.5 architecture and also use a transformer model. My algorithm uses a large amount of text data in order to learn speech patterns and structures and then be able to generate texts that are similar to that language. In order to generate text, my algorithm uses a so-called autoregressive method in which it uses the previously generated word or phrase as input in order to predict the next word or phrase. In this way text is generated step by step, each step based on the previous. Through perpetual adjustment of the emphasis in the model, depending on how good it is as predicting the subsequent text, the generative language model becomes better with time at generating text that sounds good and is realistic.⁵

This means that the answers are especially good, or make most sense, for subjects for which there are large amounts of training data. This also means, that everything that went online after the completion of the training in November 2021 has not found its way into the model

⁴You can find detailed and visual explanation by Helmut Linde here: <https://www.golem.de/news/kuenstliche-intelligenz-so-funktioniert-chatgpt-2302-171644.html>, an introductory lecture with a view to the consequences for higher education by Thomas Arnold here: <https://www.youtube.com/watch?v=c8ogAwX6KI>.

⁵ChatGPT-3.5 result, request „Wie funktioniert ein generatives Sprachmodell und der dazugehörige Algorithmus?“, 11. November 2022, German answer translated into English.

3.5; there are differences depending on release and model, but events such as the Russia–Ukraine war that started in 2022 were not known to ChatGPT in 2024.⁶ It is also not always easy to judge the quality and balanced nature of the answers – by creating a programming function you can directly test the chatbot’s suggestion. With questions that are formulated more openly, LLMs offer convincing sounding answers – though they are of course guided by the training material, the model and the training method, which are not always transparent.⁷ ChatGPT-4o answers the prompt “name ten medieval philosophers” with ten men of which seven are from Western/Central Europe.⁸ Only when told that the list is very male-biased and white does it offer a greater selection of Arabic and Persian philosophers as well as (western) women. Another query will elicit Indian and Chinese names. The large part of the texts that the model was trained with are in English, and thus from the Anglo-American sphere. A bias towards knowledge production and opinions from this sphere is thus invariable and must be taken into account.

Looking at the above reply, beautifully formulated as it is, it would seem obvious to use LLMs for all kinds of text work, and in (higher) education it caused some alarm⁹ – especially also since the programmes offered freely invented facts with great confidence, or referred to non-existent references. If people uncritically adopt results and sell it as their own text it does not only suggest capabilities that are not actually there, but the likelihood that false information is picked up and circulated, for instance in presentation, increases. As a reaction, so-called codes of conduct have been established at most universities; Basel has a new form that students have to sign, declaring that any passages created with the help of AI have been marked as such. There is of course also software able to identify texts generated by AI.¹⁰

There are also discussions about helpful uses of generative language models as learning assistants,¹¹ as writing coaches, or as research assistants, as well as successful examples of how ChatGPT can be used in teaching.¹² Central to an informed and productive use is definitely a general understanding of how the algorithms work and the preparedness to critically check the received answers, and be prepared to dismiss them if necessary.

⁶By May 2026, the newest version of ChatGPT, GPT-5.5, has training data until June 2024; [perplexity](#) has October 2023 as cut-off date, Google’s [Gemini](#) gives January 2025 as cut-off date. Newer online articles are incorporated into answers, and models can access online search, but depending on the result there is relevant information missing from the time between the completion of training and an online-search months later.

⁷The “Open” in OpenAI, the firm behind ChatGPT is thus not programmatic. The complete technical report, which nevertheless leaves out many relevant parameters, is available [here](#). For criticism of OpenAI’s methods, see for instance [this article by Leigh Mc Gowran](#). [dolly](#) is an example for an open source alternative with open training set and model, as well as Google’s [Gemma](#). The LLM [perplexity](#) advertises itself as referencing its online sources and making its results more transparent.

⁸ChatGPT-4o-result, prompt „Name ten medieval philosophers“, September 3, 2024.

⁹See [Basel jetzt](#), 19.01.2023; [NDR](#), 09.02.2023; [bajour](#), 20.03.2023; [20 minuten](#), 24.03.2023.

¹⁰The Vizerektorat Lehre has created new [guidelines](#) “Citing AI tools”.

¹¹See for instance [Pedagogical Educational Tutor \(PET\)](#), developed at the University of Hohenheim, with an [introductory video](#).

¹²See for example those by [Andrea Klein](#) or [Ethan Mollick](#).

4 Data Gathering, Data Processing, Data Analysis

Every kind of research is reliant on data, be it gathered by questioning people, medical measurements, web scraping or the interpretative analyses of texts. On the basis of data, research questions can be answered, theses postulated, hypotheses refuted, narratives strengthened. Analyses that rely on a small set of sources, or data, often present their results in the form of syntheses, which result from a previous interpretation of the documents. Via the source bibliography and references in the text, the source basis becomes comprehensible; that a certain passage, sentence or word can be interpreted in a certain way though is also due to the influence of the researchers themselves – a literature scholar for example, who wrote their PhD on male figures in Joanne K. Rowling’s work, will read *The Cuckoo’s Calling* (see Section 2.2) differently from a long-time Harry Potter fan, with much reading experience but different, less formal education. In the discussion around the text’s authorship, each will have different arguments for or against Rowling’s authorship, both will give well-founded arguments, both will refer to their experience and engagement with Rowling’s work and both will use individual passages or sentences in order to strengthen their argument, which a third person might use to argue exactly the opposite. The data basis is the same, and understandable, but the data evaluation, or the strategy by which it is evaluated is not, and thus the results gained, which again are research data, are not either.

Computer based analyses have the aspiration that all individual steps should be comprehensible, and thus that they produce reusable data: not just the source basis, i.e. the generation of data and the creation of a data set, but all the steps from the enrichment and refinement of data and the methods or programmes used for analysis to data storage and archiving should also be transparent, well-documented and comprehensible. For one, in order for the results and statements based on them to be credible, for another to allow the data to be accessible for further use, free of cost. We shall discuss the principles one should follow when working with data in [chapter 5](#). For the moment we are talking about the individual steps that are frequently needed in digital history projects: data gathering, data processing, data analysis and data storage.

4.1 Data Gathering

There are different methods you can use to gather data for historical research, we shall just mention a few in the following.

For periods of time in which there are relatively few sources and we have no serial data, **digitisation of texts** and their subsequent analysis is useful. Digitisation does not simply mean the transformation of a physical source into an image, but also enriching the picture with layout and text: only by marking those areas that are present in the text is it possible in a second step to recognise the text as such, and make it readable by a machine, and thus analyseable. This kind of transformation from image to text is possible both for modern texts, for which there is a typescript, and for premodern manuscripts or prints, in Latin script as well as in Arabic, Chinese or Japanese. There are fee-based programmes such as [Abbyy FineReader](#), but also open-source tools with or without a graphical user interface (GUI). Quite well known is [Transkribus](#), which compiles a number of functionalities; but the text recognition is liable to a fee after a certain number of pages, though some student's projects can be funded on request. Programmes that are run via the command line, are entirely free of charge and also offer a number of functionalities, are for instance [eScriptorium](#), [Kraken](#), [OCR4all](#), [OCROPUS](#) or [Calamari](#).

For the **extraction of data** from digital/digitised texts there are a number of possibilities: you can use small command line programmes (these tend to be tricky to use and difficult to read) or packages for programming languages, for the humanities usually R or Python (see Section [B.3](#)). With these you can, for example, extract entities from digitised telephone books (person names, street names, employment) or from old theatre programmes (actors, directors, etc) and use them as data sets.¹

The initial effort it takes to create automated data extraction and the steep learning curve for the use of some of the necessary programmes can be daunting at first. If you only want to analyse one theatre programme, you are sure to be quicker if you just enter the relevant data into a table. But if you have a larger corpus of sources with similar internal structure, such as a telephone book or a series of theatre programmes, it hardly makes a difference whether you are analysing ten or a hundred with the help of a script. And in addition to that you can let others use your script, or use it for similarly structured data in another project.

If you want to work with already digitised collections from public institutions such as galleries, museums or archives, (so-called **GLAMs**: **G**alleries, **L**ibraries, **A**rchives, **M**useums), there is frequently the possibility of downloading data via an **interface**.² Such **A**pplication **P**rogramming **I**nterfaces (**API**) allow communication between two computers without a graphic

¹A useful tutorial for the extraction of datasets from telephone books has been created by [Lindsey Wieck](#) for a DH course at St. Mary's University in San Antonio: https://lindseywieck.com/fall_2016_sf/gatheringdataatutorial.html. [Derek Miller](#) works on Broadway shows: [Visualizing Broadway](#). The project is described [here](#) and [here](#).

²At openglam.ch you can find information about Swiss GLAM institutions that offer open data.

interface being necessary. Instead of, for example, searching for objects or documents via the search mask of the [Staatliche Museen zu Berlin](#) using different catchphrases, and then downloading the results individually, your computer can directly communicate with the museum's API and, with quite simple commands, download long lists of results for you to work with. For this kind of request you can use the command line or a programming language. You basically just need one line, as here in the programming language R:

```
library(jsonlite)
```

```
cats <- fromJSON("https://smb.museum-digital.de/json/objects?&s=katze")
```

If you want to comprehend the individual steps, you can download R [here](#). When you open the programme you first need to install the `jsonlite` package: `install.packages("jsonlite")` “Enter” installs the package. Then you can type in the two lines from above and execute them by again pressing “enter”. The results are shown with `cats + “Enter”`.

The result for your query of “katze” will be saved in the variable `cats` which can then be exported for further use as a table: `write.csv(cats, "docs/cats_smb.csv")`

The function `write.csv` saves the contents of the variable `cats` as a csv file³ under the file path “docs/cats_smb.csv” on your hard drive.

	A	B	C	D	E	F	G	H	I
1		objekt_id	objekt_name	objekt_inventarnr	objekt_erfasst_am	institution_id	institution_name	image	total
2	1	456	Katze	AM 2598	2021-11-02 21:15:59	9	Ägyptisches Museum und Papyrussammlung	data/smb/resources/images/201806/200w_21081501496.jpg	134
3	2	52029	Shinto-Götterschrein mit heiliger Katze	ID 17657 a,b	2021-11-02 21:15:59	11	Ethnologisches Museum	data/smb/resources/images/201807/200w_06173101822.jpg	134
4	3	108895	Katze auf Rädern zum Ziehen	N (35 F) 917/1995.a	2021-11-02 21:15:59	2	Museum Europäischer Kulturen	data/smb/resources/images/201808/200w_04160418311.jpg	134
5	4	256381	Einseitig bemaltes Ostrakon mit Darstellung einer Katze vor einem Opferisch mit Gans (Tefnut-Legende)	AM 3317	2021-11-02 21:15:59	9	Ägyptisches Museum und Papyrussammlung	data/smb/resources/images/202009/200w_5f5f700958cb2.jpg	134
6	5	589	Figur der Göttin Bastet in Gestalt einer sitzenden Katze	AM 11385	2021-11-02 21:15:59	9	Ägyptisches Museum und Papyrussammlung	data/smb/resources/images/201806/200w_21081927984.jpg	134
7	6	6962	"Hälfte eines breiten Rings, darauf eine gelagerte säugende Hündin" (tatsächlich Teil eines ägyptischen Sitstrums mit säugender Katze)	Misc. 8482	2021-11-02 21:15:59	10	Antikensammlung	data/smb/resources/images/201806/200w_27194138039.jpg	134
8	7	7012	Vierfüßiges Tier. Katze? (es handelt sich um einen geometrischen Löwen)	Misc. 7899	2021-11-02 21:15:59	10	Antikensammlung	data/smb/resources/images/201806/200w_27194155897.jpg	134
9	8	230034	Amorette mit Katze	1928107	2021-11-02 21:15:59	14	Kunstgewerbemuseum	data/smb/resources/images/202009/200w_5f5ea0d3c91bf.jpg	134
10	9	63364	Mädchen mit Katze	60025-04.415	2021-11-02 21:15:59	3	Museum für Asiatische Kunst	data/smb/resources/images/201807/200w_15173931440.jpg	134
11	10	106633	Geliebte Katze	N (47 B) 3/2017.35	2021-11-02 21:15:59	2	Museum Europäischer Kulturen	data/smb/resources/images/201808/200w_04153954180.jpg	134
12	11	50739	Katze	ID 51881	2021-11-02 21:15:59	11	Ethnologisches Museum	data/smb/resources/images/201807/200w_06165932553.jpg	134
13	12	51123	Katze mit Schellenbaum	ID 51948	2021-11-02 21:15:59	11	Ethnologisches Museum	data/smb/resources/images/201807/200w_06171126839.jpg	134
14	13	51234	Katze 猫	ID 50252	2021-11-02 21:15:59	11	Ethnologisches Museum	data/smb/resources/images/201807/200w_06171645114.jpg	134
15	14	51441	Erna: Katze	ID 52073	2021-11-02 21:15:59	11	Ethnologisches Museum	data/smb/resources/images/201807/200w_06171906607.jpg	134
16	15	51467	Erna: Katze	ID 52049	2021-11-02 21:15:59	11	Ethnologisches Museum	data/smb/resources/images/201807/200w_061721932133.jpg	134
17	16	51562	Erna: Katze	ID 52125	2021-11-02 21:15:59	11	Ethnologisches Museum	data/smb/resources/images/201807/200w_061727105136.jpg	134
18	17	51736	Katzen	ID 52252 a,b	2021-11-02 21:15:59	11	Ethnologisches Museum	data/smb/resources/images/201807/200w_06172711680.jpg	134
19	18	51794	Katzen	ID 52251 a-c	2021-11-02 21:15:59	11	Ethnologisches Museum	data/smb/resources/images/201807/200w_06172750863.jpg	134
20	19	51890	Katze	ID 52290	2021-11-02 21:15:59	11	Ethnologisches Museum	data/smb/resources/images/201807/200w_06172843317.jpg	134
21			Nikko "Nemuri-no-neko" "die schlafende Katze" vor dem Eingang zur Cryptomerien Allee, die zur Grabstätte des Ieyasu führt. Nach Hidori Gingoro	VIII D 12502	2021-11-02 21:15:59	11	Ethnologisches Museum	data/smb/resources/images/201807/200w_06172852239.jpg	134
22	21	50605	Kauernde Katze Neko	ID 51748	2021-11-02 21:15:59	11	Ethnologisches Museum	data/smb/resources/images/201807/200w_06165645371.jpg	134
23	22	50966	Katze	ID 51834	2021-11-02 21:15:59	11	Ethnologisches Museum	data/smb/resources/images/201807/200w_06170156251.jpg	134
24	23	83570	Fränzi mit Katze auf einer Decke liegend	KdZ 26603	2021-11-02 21:15:59	15	Kupferstichkabinett	data/smb/resources/images/201807/200w_28193302235.jpg	134
25	24	85574	St. Goar, Blick auf St. Goarshausen und Burg Katz	SM 9.13	2021-11-02 21:15:59	15	Kupferstichkabinett	data/smb/resources/images/201807/200w_28195922385.jpg	134

Figure 4.1: First rows of the results for the query “katze” using the API of the Staatliche Museen zu Berlin

³comma separated value is a format in which individual *values* can be clearly distinguished by specific delimiters, usually *commas*, and can thus be displayed in a tabular format, where each value is stored in a separate cell. Spreadsheet software like Excel, Google Sheets, or Numbers can open csv files.

In order to avoid requests that will overload their servers, most APIs have built in either an authentication or a number of maximum results per query. With the above example this means that you are not given the entire results list (134, as you can see in the column ‘total’), but only the first 24 – these settings have been implemented by the developers of the API. If you want all results, you need to read their documentation and modify your request. For those who are interested, you can find details here.⁴

⁴The API from the example is configured in such a way, that with results over 24 hits you will only be given the first 24; that is somewhat unusual, but we can deal with it by setting the maximum result to 10. That is not too high and a number with which it is easy to do sums. You can set the parameters for maximum results with `&breitenat=10`. The starting point can be changed with the parameter `&startwert=`. Thus in order to get all hits, you can ask for the results in steps of ten, and add them together. So that that doesn’t develop into a copy & paste exercise, you need to use a slightly more comprehensive variable, or a number of variables. That has the benefit that you can then search for any term.

```
base_URL <- "https://smb.museum-digital.de/json/objects?&s=katze"
cats <- fromJSON(base_URL)
start <- 0
breite <- 10
iterations <- cats$total[1]%/%10 + 1
endsize <- cats$total[1]-(iterations-1) * 10
cat_list <- data.frame()
for (i in 1:iterations){
  if(i < iterations){
    cat_list <- rbind(cat_list, fromJSON(paste(base_URL, "&gbreitenat=10&startwert=", start, sep="")))
  } else {
    cat_list <- rbind(cat_list,fromJSON(paste(base_URL, "&gbreitenat=",
                                              endsize, "&startwert=", start, sep="")))
  }
  start <- start + 10
  write.csv(cat_list, "Desktop/cat_list.csv")
}
```

First we clean the code and save the major part of the URL in `base_URL`:

```
base_URL <- "https://smb.museum-digital.de/json/objects?&s=katze"
```

The results of the query are again stored in the object `cats`:

```
cats <- fromJSON(base_URL)
```

The number of times you do this for one request is counted by the number of total results/10 + 1; the number of hits can be taken from the column “total” in the object `cats`. In R you write this as follows:

```
cats$total[1]
```

For the cat example, this gives you 134 hits, so: (134/10 without carryover)+ 1, so 14 iterations:

```
iterations <- cats$total[1]%/%10 + 1
```

Then you set the start value to 0:

```
start <- 0
```

And the maximum hits to 10:

```
breite <- 10
```

The last iteration need not retrieve the next ten hits, but only the remaining 4 (the last after 130):

```
endsize <- cats$total[1]-(iterations-1) * 10
```

Then we create an empty table, a data frame that we can gradually fill with our results. (With smaller quantities of data, the function `rbind` can be used to combine single tables; with larger quantities the iterative extension of data frames is not recommended.):

If websites do not offer APIs there is the possibility of reaching your goal with **Web Scraping**. Depending on the website or its contents however, the legal situation is not always entirely clear. To download websites with Python there is [a course in the Programming Historian](#) by William J. Turkel and Adam Crymble. A further tutorial on data acquisition by Zach Coble, Liz Rodrigues, Erin Pappas, Chelcie Rowell, and Yasmeen Shorish can be found [here](#).

4.2 Data Processing⁵

Working with data sets, be they your own or collected by a third party, it is often the case that there is information missing or collected irregularly, making a later analysis more difficult.

If in a survey among students concerning their studies, their subject is entered into a table without having first defined values for the category, you might find instead of “History” and “German” the variants “Historical studies”, “Hist.”, “Hitsory”, “German studies”, “German language and literature”, “German studies”, “Germanistics”. Instead of the two values for two subjects, you now have nine – without there actually more subjects being studied. In the best case, variants like these are prevented from the outset, by giving a set list of values. If, however, you receive a data set with different variants for one and the same word, you will need to combine these in order to have a useful data base. You could use **Ctrl-R** to try and find different variants and replace them; in programmes like Excel, Open Office or Google sheets you can have unique variants displayed in one column, and can then combine them to one base value; most helpful and easiest to use – even for large data sets – is the software

```
cat_list <- data.frame()
```

Once we have set these variables, we can build a loop that implements different actions under certain conditions: :

```
for (i in 1:iterations){
```

If the last iteration has not been reached yet, the request will be answered in steps of ten, each iteration moving the starting value of ten further, and the results are filled into the `cat_list`.

```
if(i < iterations){
```

```
cat_list <- rbind(cat_list, fromJSON(paste(base_URL, "&gbreitenat=10&startwert=", start ,
sep="")))
}
```

```
else {
```

As soon as the last iteration has been reached, not ten but the number of hits saved in `endsize` are requested, which in our example is 4:

```
cat_list <- rbind(cat_list,fromJSON(paste(base_URL, "&gbreitenat=", endsize, "&startwert=",
start, sep="")))
}
```

```
}
```

```
start <- start + 10
```

In the end, so after 14 iterations, the table is written to a file::

```
write.csv(cat_list, "Desktop/cat_list.csv")
```

```
}
```

⁵It is often said that data editing/preprocessing takes up 80% of your time leaving only 20% for analysis and interpretation. Leigh Dodds looked at these numbers in a [blog article](#) from 2020, and the numbers are not really as dramatic as that.

[OpenRefine](#), with which you can extract,⁶ clean up/normalise⁷ and enrich⁸ data in order to have a good data basis for your research question and the necessary analysis.

For text files a number of steps are needed, depending on which method or software you want to use. For most analyses it is sensible to work with so-called stop word lists. [Stop words](#) are words that have been removed from a corpus before analysis in order to get more significant results, especially when purely quantitative methods are being used for content analysis. Words with grammatical functions are present in great number in documents, but carry little individual meaning. If you analyse the raw text of this guide according to word frequency (here with [Voyant-Tools](#)), you can only guess at the subject matter. “digital” is only on 12th place, articles and prepositions are far more frequent. Using a stop word list that removes the commonest words not carrying meaning from the text, the contents are clearer:

Further steps could be [tokenisation](#), segmenting the text on word-level, and [lemmatisation](#), reducing various word forms to their one base form – “is”, “was”, “are” are turned into “be”. Just like with the variants in subjects earlier, the different variants have no added value for your research question and can be merged for further analysis. There are software and packages for these steps too, so that you need not do it all yourself. Especially for the more widely spoken modern languages, see also Section [B.3](#). For non-standardised languages or language forms (dialects or premodern texts) it is more difficult. There are programmes for this too, but how precise they are must be judged individually.

4.3 Data Analysis

If you have a data set, either from your own data or someone else’s, and have done preprocessing for your own use, you are (finally) ready to analyse it. What method or software you use depends not only on the type and amount of data you are working with, as well as the format your data is in, it also depends on your research question. If you have got a data base with correspondents (authors and addresses) of whom you know where they live but have forgotten to note the dates of the individual letters, you can only illustrate a spatial distribution, but hardly one across time and space.⁹ If you are only interested in the spatial distribution of female and male authors but are not interested in the question of when, then it is hardly necessary to record this information. Before you decide on your method, you need to ask

⁶Evan Peter Williamson: Fetching and Parsing Data from the Web with OpenRefine, *Programming Historian* 6 (2017), <https://doi.org/10.46430/phen0065>.

⁷Seth van Hooland, Ruben Verborgh, Max De Wilde: Cleaning Data with OpenRefine, *Programming Historian* 2 (2013), <https://doi.org/10.46430/phen0023>.

⁸Karen Li-Lun Hwang: Enriching Reconciled Data with OpenRefine, *The Bytegeist Blog* 2018, <https://medium.com/the-bytegeist-blog/enriching-reconciled-data-with-openrefine-89b885dcadb>

⁹A large project of Stanford University, “[Mapping the Republic of Letters](#)”, has modeled the correspondence network of 18th century scholars through their letters. One example is that of Voltaire, in different visualisations: <http://republicofletters.stanford.edu/publications/voltaire/letters/>. Dan Edelstein. Interactive Visualization for Voltaire’s Correspondence Network. Letters in Voltaire’s Network [Created using Palladio, <http://hdlab.stanford.edu/palladio>].

		Term	Count
☐	1	und	191
☐	2	die	170
☐	3	https	150
☐	4	in	119
☐	5	der	101
☐	6	sie	96
☐	7	für	89
☐	8	von	87
☐	9	zu	83
☐	10	mit	74
☐	11	ist	72
☐	12	digital	66
☐	13	sich	64
☐	14	data	61
☐	15	oder	50
☐	16	zur	49
☐	17	eine	49
☐	18	daten	49
☐	19	ein	47
☐	20	das	46
☐	21	es	44
☐	22	werden	42
☐	23	den	37
☐	24	auf	37
☐	25	um	36

(a) Word frequencies raw text

		Term	Count
☐	1	https	150
☐	2	digital	66
☐	3	data	61
☐	4	daten	49
☐	5	history	35
☐	6	wiki	32
☐	7	doi.org	29
☐	8	tools	24
☐	9	online	23
☐	10	en.wikipedia.org	23
☐	11	quellen	21
☐	12	command	21
☐	13	chapter	21
☐	14	shell	18
☐	15	digitale	18
☐	16	text	17
☐	17	arbeit	17
☐	18	analyse	16
☐	19	terminal	15
☐	20	line	15
☐	21	interface	14
☐	22	geschichte	14
☐	23	forschung	14
☐	24	ressourcen	13
☐	25	literacy	13

(a) Word frequencies with stop words excluded

yourself how and to what end you want to use your data set and which questions you would like answered. In a next step we should think about the specific type of analysis that is possible with the existing data. Among the many possibilities for working with **structural data**, the methods most commonly used in history are [network analysis](#) or [regression analysis](#). For **textual data** there are also a number of forms of analysis, for instance word frequency count as part of [stylometry](#)/attribution of authorship (see Section 2.2), [topic modeling](#) as statistical method for identifying recurring themes in larger corpora, or [sentiment analysis](#) for extracting emotions, feelings and values from text passages. If you have **georeferenced data**, you can analyse and visualise your data in various ways with the help of [GIS](#) (Geographic Information System).

Whether you use your own script for topic modeling or use existing software, whether you do your regression analysis yourself or via websites, remains your own decision. It is often a good idea to use existing online possibilities for initial short analyses in order to decide whether the intended method really can give the hoped-for results. For larger projects, in which you will perform complex analyses over a longer period of time, it could be a good idea to work with a programming language simply because you can then adjust the functions to your own needs and have full control over your data. A list of tools frequently used for historical analysis can be found in Section B.3.

4.4 Data Storage

In [chapter 5](#) we will be looking at how to store your research data sustainably. At this point I shall just mention that beside storing your data, it is sensible to use version control and provide a detailed documentation. **Data versioning** has the advantage that you can redo individual steps, save data at various different stages and for later use, and attribute them to different team members. Additional version control is more than the regular back-up done by back-up programmes or clouds such as dropbox or Switchdrive, and for collaborative work in academia as well as industry, the use of [git](#) has established itself, often in combination with data/code repositories on [GitHub](#). Most of you will probably not have personal GitHub repositories, but will at some point use the system, mainly by downloading data that has been provided. The text data for this guide is also on a [GitHub repository](#). Finally, the **documentation** of stored data comprises information about the development of the data set. How and by whom was the data collected? How was it annotated? In what format is it available? What software was used where? What does it depict? Storing data in different places, for instance on your local hard drive, in a cloud and on a flash-drive, can save you from losing it. Documentation and storing it on a repository, a long-term storage space for data, gives it additional visibility and the possibility for reuse. Repositories for the humanities are for instance [DARIAH-DE](#) or the [DaSCH](#); there are very specialised repositories or ones that are open to all disciplines such as [Zenodo](#) (run by Cern). You can deposit your data there for free, have your authorship recognised, and give the data/publication a Digital Object Identifier (DOI), an individual and enduring digital identifier, which makes it permanently citable.

5 FAIR, CARE and LOUD

Already at the beginning of a project, be it a seminar paper or a large collaborative project, you should ask yourself questions about storage, compatibility and reusability of research data. Too often projects end without the data that has been produced being made usable for later research, either because nobody thought of looking for options for permanent storage, or because the data was collected and saved in a form that makes future reuse difficult or even impossible. At the latest when you visit the archives – be it analogue or digitally – and are going to transcribe a document, you will probably ask yourself whether that has not already been done by somebody else, and you could save yourself the job, or if you will want to offer your own transcriptions to other people. The question is simply where, and how.

At the beginning of your studies, such questions are presumably not yet central; but still some questions surrounding securing, storing, and reusing data and data formats shall be looked at briefly here, in order to create awareness, but also because they influence the [data gathering](#).

5.1 FAIR Data

The principles of FAIR data were defined in 2016 by a consortium of academics and organisations as follows:^[10] **F**indability, **A**ccessibility, **I**nteroperability, **R**euse of digital assets.

Data should be **findable** and **accessible**, **interoperable** (usable with different systems) and **reusable**. If you take photographs of ten wills from the 18th century in the Basel State Archives for a seminar paper and subsequently transcribe them, identify the objects mentioned, compare the testators and hand in your results on paper to your tutor, your data is the exact opposite. Nobody knows that you have collected the data, it cannot be found via general search tools but only via personal contacts, and if your tutor would like to put it at the disposal of other students in order to encourage further research, they need to do it by copying your printed paper. Paper copies are neither interoperable nor sensibly reusable – you need to type them into a computer in order to make them readable by a machine and to be able to work with them. If, however, you publish your transcribed texts and identified objects – in a standardised format and with an open licence – on a repository, you are not only making important parts of your work visible, but also making further research easier.¹ You can also ensure that the work does not have to be done twice.²

¹For different repositories see Section 4.4.

²The platform [transcriptiones](#) allows transcriptions to be shared easily.

5.2 CARE Principles

Following the FAIR principles, the Global Indigenous Data Alliance formulated the CARE principles for dealing with indigenous data in 2019:[2] **C**ollective Benefit, **A**uthority to Control, **R**esponsibility, **E**thics.

The focus is not just on propagating open data and sharing of data, but also to consider the people involved and the goals in order not to reinforce existing power imbalance between different actors. Indigenous data should serve **collective use**, there should be a **right to control**, **responsibility** should be taken for the use of the data, and **ethical principles** taken into account. Even though these guidelines are specially worked out for the use of indigenous data, they are an addition to the data centered approach formulated in the FAIR principles that takes into account the origin of the data and urges a reflective use.

5.3 LO(U)D

Tim Berners-Lee, the inventor of the World Wide Web, early on promoted standardised digital data could be linked, and thus the development of a [Semantic Web](#), in which data is human and machine readable:

The Semantic Web isn't just about putting data on the web. It is about making links, so that a person or machine can explore the web of data. With linked data, when you have some of it, you can find other, related, data.³

In order not simply to be able to find data but to be able to reuse and combine it, principles have also been formulated for **Linked Open Data**, which should be adhered to when creating or publishing data; well-known examples for LOD data sets are [Wikibase](#), [Wikidata](#) or [GeoNames](#).

Berners-Lee suggested a five-star system to classify open data sets, wherein five stars is the equivalent of Linked Open Data.

1 Star: A data set is openly accessible, in a random format, for instance as a pdf.

2 stars: a data set is openly accessible in a structured format, for instance Microsoft Excel (.xls).

3 stars: a data set is openly accessible in a non-proprietary format, for instance as comma separated values (.csv).

4 stars: a data set follows the standards of the World Wide Web Consortium ([W3C](#)), such as using Resource Description Frameworks ([RDF](#)) and adopting Uniform Resource Identifiers ([URIs](#)).

5 stars: a data set fulfills all the above criteria and in addition it contains links to other Linked Open Data.

³Tim Berners-Lee: Linked Data, 2009. Online: <https://www.w3.org/DesignIssues/LinkedData.html>.

Going even further, **Linked Open Usable Data** principles aim at not only providing data in open and linked form, but also to structure them in a comprehensible way and to document them in order to secure their reusability.

It is unlikely that you will have to think about things such as the W3C, RDF and URIs during your studies, but be aware that your research data is more visible and reusable if you choose a file format that does not only work on one operating system or needs a programme that is not freely available.

Part II

Practical Section

Hands on

Im Praxisteil sollen verschiedene Schritte rund um die **Datenerhebung** – wie komme ich von Quellen zu (strukturierten) Daten, und was ist das überhaupt? –, die **Datenaufbereitung** – wie kann bzw. muss ich die Daten für meine Zwecke bearbeiten – und die **Datenanalyse** – wozu sind die strukturierten Daten da, und was mache ich damit? – an einem kleinen Beispiel durchgeführt werden. Dabei werden viele Praktiken und Konzepte nur angeschnitten, die bei Interesse mithilfe weiterführender Literatur und Tutorials vertieft werden können. Manch eine:r wird Inhalte vermissen – Lücken sind unvermeidbar, aber Anregungen sind herzlich willkommen.

Als Quellenbeispiel dient eine Briefsammlung, die im Rahmen der digitalen Edition “Der Sturm” an der Akademie der Wissenschaften in Mainz erstellt wurde.⁴ Das Projekt, das Briefe von Personen der internationalen Avantgarde rund um die Zeitschrift “Der Sturm” aufbereitet, hatte dabei unterschiedliche Nutzer:innengruppen im Blick und stellt die Quellen bzw. die erstellten Daten auf verschiedene Weise zur Verfügung: Auf der Webseite des Projekts können die **bisher edierten Briefe** am Bildschirm gelesen werden, und es gibt ein Register der in den Texten genannten Entitäten, also Einheiten, hier der **Personen**, **Orte** und **Werke**; darüberhinaus gibt es die Möglichkeit, über eine **Schnittstelle** die Quellen oder die Registerdaten herunterzuladen. Wir können uns den Briefen also über den Vordereingang, die Webseite, oder durch die Hintertür, mittels Kommandozeile, nähern, und beide Herangehensweisen vergleichen. Grundlegende Konzepte für die Arbeit mit Daten, bzw. für die Schritte von der Quelle zum Datensatz, werden angesprochen.

Briefe sind eine gängige Quellengattung in den verschiedenen Epochen/Areas, und sie können sowohl für Textanalysen als auch zur Gewinnung von Strukturdaten genutzt werden. Das Beispiel zielt also auch auf eine größtmögliche Nähe zur tatsächlichen historischen Arbeit.

⁴DER STURM. Digitale Quellenedition zur Geschichte der internationalen Avantgarde, erarbeitet und herausgegeben von Marjam Trautmann und Torsten Schrader. Mainz, Akademie der Wissenschaften und der Literatur, 2018. Online: <https://sturm-edition.de/>, Lizenz: CC-BY-4.0.

6 ‘Der Sturm’ – Edited Correspondence

Die Webseite <https://sturm-edition.de/> dient als Portal für die Arbeit mit Quellen zum avantgardistischen STURM-Unternehmen, das mit der Gründung der gleichnamigen Zeitschrift in Berlin im Jahr 1910 durch [Herwarth Walden](#) begann und mit den nachfolgenden Gründungen einer Galerie, einer Bühne und eines Verlags internationale Bedeutung erlangte. Neben Walden waren weitere Akteur:innen an diesem Unternehmen beteiligt, und bisher (Stand Herbst 2024) sind 179 Briefe von drei Künstler:innen an Walden im Portal verfügbar. Zudem wurden die Zeitschrift, Ausstellungskataloge, Jahrbücher, Verlagsschriften und weitere Materialien wie Plakate, Fotografien oder Einladungskarten digitalisiert.

Gehen Sie auf die [Startseite](#) und lesen Sie die Kurzbeschreibung zu den Briefen, Personen, Orten und Werken, um eine erste Idee vom Material zu bekommen. Klicken Sie dann die Briefabteilung an und schauen sich Brief Nummer 8 von [Franz Marc](#) an Herwarth Walden an.

Wie Sie sehen können, wurde der Brief nicht nur digitalisiert, also in ein digitales Bild umgewandelt, das Sie über einen externen Viewer betrachten können, sondern auch historisch-kritisch ediert und nach den Richtlinien der TEI P5 in XML codiert.

Was bedeutet das genau, und wieso ist es wichtig für unsere Arbeit als Historiker:innen?

Bei einer historisch-kritischen Edition wird keine reine Leseversion eines Textes erstellt, wie man es beispielsweise von der Textdarstellung in einem Roman kennt, sondern zusätzliches Material zum besseren Verständnis des Texts herangezogen und als Information in einem sog. kritischen Apparat zur Verfügung gestellt. Beispielsweise werden Quellen, die ein:e Verfasser:in für bestimmte Textpassagen als Vorlage genutzt hat, genannt, oder auf Ereignisse während der Entstehungszeit, die Einfluss auf den Text hatten, verwiesen. Entitäten wie Personen, Orte, Werke usw. werden erklärt oder kommentiert. Der Text selbst wird so quellengetreu wie möglich dargestellt, orthographische oder grammatikalische Fehler werden nicht korrigiert, und meist werden auch extratextuelle Elemente wie Durchstreichungen oder Hervorhebungen im Lesetext dargestellt.

[1914-04-14 / Sindelsdorf]

➤ [185v]

Angabe der Follierung,
d.h. der Seite im Quellenbestand
in der Staatsbibliothek zu Berlin

[Empfänger]

Herr
Herw. Walden
Verlag „Sturm“
Berlin W. 9.
Potsdamerstr. 134/a

➤ [185r] L. W,

bestätige mit vielem Dank 60 Mk für 2 Holzschnitte. Auch diese kleinen Verkäufe nutzen mir momentan sehr. Ich habe wohl neun Holzschnitte in Arbeit, aber alle für die Illustration an der **Genesis** gedacht, die ich keinesfalls vorher veröffentlichen darf. Aber ich werde noch suchen, nebenbei für den **Sturm** ➤ (i) ein paar neue zu schneiden. Hat **Arnold** eigentlich die Bilder aus **Breslau** (3 kleine Kompositionen u. **Wasserfall**) Ihnen zugesandt? Ich habe von dort nichts gehört. Vollmacht hab ich geschickt. Ist **Klugen** ganz vom Erdboden verschwunden. Ich hegte noch immer stille Hoffnungen auf ihn. Auf die komische Sache bin ich neugierig. Daß **Aug. Macke** in der | Sezession ausgestellt haben soll, kann ich schwer glauben, wenigstens nicht von sich aus. **C.** wird die Sachen von anderer Seite haben. Oder ist es vielleicht **Hellmuth Macke**? **August** ist momentan mit **Klee** u. **Moillet** in **Tunis**!

Hrztl.

Ihr **FMarc**.

1. Die Tunisreise von Klee, Macke und Moillet wird in der Kunstgeschichte als bedeutendes Ereignis für die moderne Kunst behandelt. Vgl. Güse, Ernst-Gerhard: Die Tunisreise. Klee, Macke, Moillet. Stuttgart 1982. »

FAKSIMILES DIESER QUELLE



Bestandshaltende Institution: Staatsbibliothek zu Berlin - Preussischer Kulturbesitz. Lizenz: Public Domain.

Digitalisierter Brief

Klick auf "DFG-Viewer"
führt zu Darstellung in
externem Viewer

Repräsentation von
extratextuellen Elementen
wie Unterstreichungen

Kritischer Apparat mit
Erläuterung zur Tunisreise,
die im Text genannt wird

Figure 6.1: Brief Nr. 8 von Franz Marc an Herwarth Walden.¹ Rote Einfärbung kennzeichnet eine Verlinkung, meist auf Entitäten wie Personen oder Orte.

Wie genau die Editor:innen jeweils vorgegangen sind – dies unterscheidet sich von Edition zu Edition –, wird in den jeweiligen Editionsrichtlinien vermerkt. Für die Quellen des STURM-Projekts gibt es verschiedene Richtlinien, je nach Quellenart. Die der Briefedition finden Sie [hier](#).

Eine Codierung in XML bedeutet, dass eine Textdatei mit der **Extensible Markup Language** ausgezeichnet wurde, d.h. Strukturen im Text werden durch festgelegte Zeichen so markiert, dass sie sowohl von Menschen als auch von Computern interpretiert werden können. Etwas

¹Online unter <https://sturm-edition.de/quellen/briefe/fma/Q.01.19140414.FMA.01.html>

geläufiger ist Ihnen vermutlich HTML, [Hypertext Markup Language](#), eine Sprache zur Auszeichnung elektronischer Dokumente. Die Prinzipien sind dabei ähnlich: Festgelegte Elemente werden durch einen öffnenden und einen schließenden Tag ausgezeichnet, z.B.

`<salute>Hrzl.</salute>`,

um die Grußformel in einem Brief (wie in Brief Nummer 8, siehe oben) als solche zu markieren. Das hat den Vorteil, dass bei der Suche nach Grußformeln nicht konkrete Begriffe formuliert werden müssen, sondern nach dem entsprechenden Element `<salute>` gesucht werden kann, und zwar sowohl vom Menschen als auch von der Maschine. Darauf kommen wir nochmals zurück. Zunächst betrachten wir die Briefe auf der Webseite.

7 Through the Front Door

Stellen Sie sich vor, Sie würden für ein Forschungsprojekt unter anderem die Briefe von Franz Marc an Herwarth Walden untersuchen wollen. Sie wären bei Ihrer Untersuchung daran interessiert, welche Grußformeln Marc in seinen Briefen an Walden benutzte, um aus eventuellen Änderungen Rückschlüsse auf das Verhältnis der beiden ziehen zu können. Wie würden Sie vorgehen, um sich eine Übersicht zu verschaffen? Würden Sie eine Downloadmöglichkeit der Webseite nutzen oder die Briefe online lesen? Welche Schritte würden Sie durchführen, um die Texte aller Briefe von Marc und Walden auf Ihrem Computer zu speichern? Notieren Sie Ihr Vorgehen zu den Fragen in einem Dokument.

Es gibt zahlreiche Wege, die zum Ziel führen, und keiner ist dabei besser oder schlechter; aber manche sind möglicherweise effizienter als andere – das heißt, Sie sparen Zeit, die Sie für andere Dinge verwenden können, sei es fürs Studium oder in der Badi.

Egal, wie Sie vorgegangen sind, erledigen Sie folgende Aufgaben:

1. Erstellen Sie eine Übersicht über alle Grußformeln in den 45 Briefen von Franz Marc an Herwarth Walden. Welches Format – analog oder digital – bzw. welchen Dateityp Sie wählen, bleibt Ihnen überlassen.
2. Nehmen Sie Brief Nr. 8 von Marc an Walden und unterteilen Sie ihn in strukturelle Elemente.

Ob Sie den Brief hierfür ausdrucken und Strukturelemente mit einem Stift markieren oder ob Sie am Computer arbeiten, können Sie wählen. Was Sie als Strukturelement verstehen, ist Teil der Aufgabe.

(Bei einem Gedicht wären mögliche Strukturelemente etwa Titel und Strophe.)

3. Nehmen Sie denselben Brief und markieren Sie Entitäten, also Einheiten wie Personen, Orte, etc. Erstellen Sie hierfür ein Tabellendokument (mit Excel, Google Sheets, Open Office o.Ä.), in das Sie die Entitäten aufnehmen.

Nachdem Sie die Aufgaben erledigt haben, lesen Sie “The Ten Commandments of Inputting Data” in Kapitel 3 im Buch “Quantitative Methods in the Humanities”.[\[6](#), S. 57–60] Das Kapitel finden Sie im ADAM-Workspace Ihres Einführungskurses – es lohnt sich als Ganzes, aber die “Ten Commandments” reichen auch. Eine eher praxisorientierte Onlinefassung finden Sie [hier](#) im das Buch begleitenden Blog.

Würden Sie nach der Lektüre bei Aufgabe 3 anders vorgehen? Notieren Sie sich etwaige Änderungen bzw. Erkenntnisse und bringen Sie Ihre Resultate zur begleitenden Sitzung mit, in analoger oder digitaler Form.

8 Through the Back Door

Bevor wir uns näher mit dem Beispielkorpus der Briefedition befassen, werfen wir einen kurzen Blick auf die Interaktionsmöglichkeiten mit dem Computer und wie wir diese für unsere Arbeit als Historiker:innen nutzen können, sei es für die Erhebung, die Aufbereitung oder die Analyse von Daten.

Es gibt zwei Arten, um mit einem Computer zu interagieren bzw. ihn zu nutzen: über ein **Graphical User Interface** (GUI), also vor allem mit der Maus und durch das Anklicken von Objekten, oder, etwas direkter, über die [Kommandozeile](#).¹ Um via GUI eine Datei “Brief1.txt” im Ordner “Briefe” zu löschen, öffnet man den Finder (Mac), den Explorer (Windows) oder den Filebrowser der Wahl (Linux), klickt sich zum Ordner “Briefe”, macht einen Rechtsklick auf die zu löschende Datei “Brief1.txt”, klickt “In den Papierkorb legen” oder zieht die Datei mit der Maus direkt dorthin. Dieselbe Aktion kann man als Kommando schreiben: Man öffnet das Terminal (Linux oder Mac; den Finder öffnen und im Suchfenster “Terminal” eingeben und Programm öffnen) oder eine PowerShell (Windows; mit der rechten Maustaste auf das Startsymbol klicken, dann “Windows PowerShell” auswählen), navigiert im sich öffnenden Fenster mit Texteingabe zum entsprechenden Ordner, bspw. `cd Documents/Briefe` + ‘Enter’ (Mac und Linux) bzw. `cd ./Documents/Briefe` (Windows) und gibt dort das Kommando `rm Brief1.txt` ein, das mit der Entertaste ausgeführt wird.

```
(base) serina00@dg-19-mac-02 ~ % cd Documents/Briefe
```

```
(base) serina00@dg-19-mac-02 Bilder % rm Brief1.txt
```

Vorgehen in der Kommandozeile bzw. im Terminal auf MacOS

Die beiden Vorgehensweisen unterscheiden sich dabei in drei Punkten:

1. Das Kommando `rm` ist endgültig, die Datei ist ohne Übergangszeit im Papierkorb gelöscht.

¹Kommandozeile/Command Line, Bash, Shell oder Prompt finden sich oft als synonym genutzte Begriffe für Command Line Interfaces. Auf UNIX-basierten Betriebssystemen wie Mac OS und Linux ist das Terminal als Interface weit verbreitet; für Details: https://en.wikipedia.org/wiki/Command-line_interface#History. Windowsnutzer:innen kommen mit der PowerShell ganz gut zurecht, es empfiehlt sich eventuell die Installation von [Cygwin](#) oder [MinGW](#), um mit einem UNIX-basierten Interface arbeiten zu können.

2. Das Kommando lässt sich relativ simpel auf eine Vielzahl von Dokumenten anwenden, wobei ganz unterschiedliche Bedingungen beachtet werden können, und es lässt sich mit anderen Kommandos verbinden.
3. Terminal sieht k3wl aus.

Bevor wir den zweiten – und für unsere Arbeit hilfreichsten – Unterschied genauer anschauen, kurz zur Kommandozeile.

8.1 Shell 101

In einem Terminal/einer Shell – zur Unterscheidung siehe Fußnote 1 – können Kommandos bzw. Programme ausgeführt werden, die auf der *Strukturebene* stattfinden – wie beispielsweise das Löschen einer Datei, `rm Dateiname.xyz` (`rm` für *remove*), oder das Erstellen eines Ordners, `mkdir NeuerOrdner` (`mkdir` für *make directory*). Ebenso möglich sind Operationen auf der *Inhaltsebene* – wie beispielsweise das Suchen eines bestimmten Begriffs in einer Textdatei, `grep 'Begriff' Textdatei.txt` (Mac/Linux) bzw. `Select-String -Path Textdatei.txt -Pattern 'Begriff'` (Windows), oder das Auszählen mehrerer Begriffe und das Speichern des Ergebnisses in einer neuen Datei, `grep -Ec '(Begriff1|Begriff2)' Textdatei.txt | wc -l > Ergebnisse.txt` (Mac/Linux) bzw. `(Select-String -Path Textdatei.txt -Pattern '(Begriff1|Begriff2)'.Matches.Count > Ergebnisse.txt` (Windows) – die Kommandos werden weiter unten nochmals einzeln erklärt.

Woher weiss Ihre Shell aber, was sie ausführen soll, wenn Sie `rm` oder `grep/String-Select` eintippen? Es gibt zahlreiche Shell-Programme, die bereits auf Ihrem System vorinstalliert sind, und mit denen Sie vieles tun können – öffnen Sie Ihre Shell, tippen Sie `date` ein und drücken ‘Enter’: Das aktuelle Datum mit Uhrzeit erscheint. (Ihre Shell sucht nach dem ersten Argument, dem Befehl `date`, im Filesystem des Computers, und wenn sie fündig wird, führt sie eine Aktion mit den entsprechenden Parametern aus.)

Note

tmi: Wenn Sie `echo $PATH` im Terminal (Mac/Linux) bzw. `$env:PATH` (Windows) eingeben, sehen Sie eine Auflistung der Orte, an denen nach Befehlen gesucht wird. Tippen Sie `which date` ein und drücken Sie ‘Enter’, um zu sehen, wo das Programm “date” in Ihrem Computer liegt.

Falls Sie einen Befehl eintippen, den es nicht gibt bzw. für den kein installiertes Programm auf Ihrem Computer existiert, bekommen Sie eine simple Fehlermeldung – kaputtgehen kann dabei nichts:

```
(base) serina00@dg-19-mac-02 ~ % nonsense
```

```
command not found: nonsense
```

Der Output auf Windows ist etwas ausführlicher:

```
nonsense: The term 'nonsense' is not recognized as a name of a cmdlet, function, script file, or executable program. Check the spelling of the name, or if a path was included, verify that the path is correct and that the file exists.
```

Das aktuelle Datum wird Ihnen wahrscheinlich auch in Ihrer Toolbar angezeigt, und einen neuen Ordner können Sie per Rechtsklick erstellen, dazu brauchen Sie das Terminal nicht unbedingt. Um einen Begriff in einem Textdokument zu finden und alle Vorkommen zu zählen, können Sie das Dokument öffnen, **Strg-F** drücken, den Begriff eingeben und das Ergebnis sehen. Wenn Sie nach mehreren Begriffen suchen wollen, müssen Sie dieselbe Aktion zweimal ausführen: **Strg-F**, Begriff 2. Und wenn Sie mehrere Dateien durchsuchen möchten, beispielsweise um herauszufinden, wie oft die Grußformel “Mit herzlichem Gruß” in einer Briefsammlung vorkommt, müssen Sie die Suche in jeder Datei einzeln ausführen. Wenn Sie dann noch nach der Variante “Mit herzlichen Grüßen” oder gar “Herzl. Gruß” suchen wollen, vervielfacht sich Ihre Arbeit.

Sie können dasselbe auch mit dem Terminal machen und einige der Built-in-Programme nutzen, um sich Zeit und Arbeit zu sparen.

8.2 Ctrl-F 2.0

Wir arbeiten wie im vorangegangenen Kapitel mit einem Teilkorpus der Quellenedition “Der Sturm”, nämlich mit allen Briefen, die von [Franz Marc](#) verfasst wurden. Um die folgenden Schritte nachzuvollziehen, laden Sie sich den Ordner “letters_Der_Sturm” herunter. Sie können dazu entweder das vollständige [GitHub-Repository zu diesem Guide](#) als Zip-Datei herunterladen und entpacken, und im Ordner “docs” befindet sich der Ordner “letters_Der_Sturm”.




Figure 8.1: GitHub-Repositorium mit Quellcode, Download via “Code” und “Download ZIP”.

Sie können das Repositorium auch über die Kommandozeile klonen

```
git clone https://github.com/wissen-ist-acht/digitalhistory.intro.git
```

oder als bequeme Variante diesen [Direktlink](#) nutzen.

Wenn Sie die [Schnittstelle der Webseite](#) ausprobieren wollen, kommen Sie mit wenigen Kommandos an die Dateien.

🔥 Download per Schnittstelle

Mit dem ersten Kommando erstellen wir eine Datei “briefe_marc.xml” mit den Dateinamen aller Briefe, die von Franz Marc geschrieben wurden – über das Register auf der Webseite wissen wir, dass er die Personen-ID P.0000003 hat; die URL zur Abfrage der Schnittstelle können wir der [Dokumentation](#) entnehmen: Mac/Linux:

```
curl https://sturm-edition.de/api/persons/P.0000003 --output briefe_marc.xml
```

Windows:

```
Invoke-WebRequest -Uri "https://sturm-edition.de/api/persons/P.0000003" -OutFile "briefe_ma
```

Wenn Sie die Datei mit einem Editor öffnen, der XML-Dateien lesen kann, sehen Sie, dass neben den Dateinamen, die nach “target=” stehen, noch viel Beifang ist, den wir loswerden möchten:

```
<person xmlns="http://www.tei-c.org/ns/1.0" source="http://d-nb.info/gnd/11857745X" xml:id="
  <persName type="pref">Marc, Franz</persName>
  <persName type="fn">Franz Marc</persName>
  <linkGrp type="files">
    <ptr n="Bl.375" target="Q.01.19191212.JVH.01.xml"/>
    <ptr n="Bl.377" target="Q.01.19200114.JVH.01.xml"/>
    <ptr n="Bl.219" target="Q.01.19160128.FMA.01.xml"/>
    <ptr n="Bl.222" target="Q.01.19160205.FMA.01.xml"/>
    <ptr n="Bl.223" target="Q.01.19160302.FMA.01.xml"/>
    <ptr n="Bl.218" target="Q.01.19160101.FMA.01.xml"/>
    <ptr n="Bl.221" target="Q.01.19160122.FMA.01.xml"/>
    <ptr n="Bl.220" target="Q.01.19160115.FMA.01.xml"/>
    <ptr n="Bl.207" target="Q.01.19150703.FMA.01.xml"/>
    ...
  </linkGrp>
</person>
```

Denn eigentlich brauchen wir nur die Dateinamen, um die Dateien mit einem entsprechenden Befehl herunterladen zu können. Auch sehen wir, dass nicht nur Briefe mit dem Kürzel “FMA” für Franz Marc gelistet sind, sondern auch neun mit “JVH”, Jacoba van Heemskerck. Beim Blick in die betreffenden Dateien zeigt sich, dass in diesen Franz Marc jeweils erwähnt und im TEI-XML mit `persName key="P.0000003"` getaggt wurde, daher Teil des Abfrageergebnisses ist. Mit dem zweiten Kommando erstellen wir eine neue Datei, in der die einzelnen extrahierten Dateinamen ohne diejenigen von Jacoba van Heemskerck mit dem Download-Kommando `curl` kombiniert und um die entsprechende URL zum Download ergänzt werden:

Mac/Linux:

```
cat briefe_marc.xml | grep -o 'Q.*FMA.*.xml\b' | perl -nle 'print "curl -o $_ https://sturm-
```

Windows:

```
Select-String -Path "briefe_marc.xml" -Pattern 'Q.*FMA.*.xml\b' | ForEach-Object {
    $match = $_.Matches[0].Value
    "curl -o $match https://sturm-edition.de/api/files/$match"
} > dateinamen_briefe_marc.txt
```

Die Datei “dateinamen_briefe_marc.txt” sieht so aus:

```

curl -o Q.01.19160128.FMA.01.xml https://sturm-edition.de/api/files/Q.01.19160128.FMA.01.xml
curl -o Q.01.19160205.FMA.01.xml https://sturm-edition.de/api/files/Q.01.19160205.FMA.01.xml
curl -o Q.01.19160302.FMA.01.xml https://sturm-edition.de/api/files/Q.01.19160302.FMA.01.xml
curl -o Q.01.19160101.FMA.01.xml https://sturm-edition.de/api/files/Q.01.19160101.FMA.01.xml
curl -o Q.01.19160122.FMA.01.xml https://sturm-edition.de/api/files/Q.01.19160122.FMA.01.xml
curl -o Q.01.19160115.FMA.01.xml https://sturm-edition.de/api/files/Q.01.19160115.FMA.01.xml
curl -o Q.01.19150703.FMA.01.xml https://sturm-edition.de/api/files/Q.01.19150703.FMA.01.xml
curl -o Q.01.19150417.FMA.01.xml https://sturm-edition.de/api/files/Q.01.19150417.FMA.01.xml
curl -o Q.01.19151106.FMA.01.xml https://sturm-edition.de/api/files/Q.01.19151106.FMA.01.xml
curl -o Q.01.19150918.FMA.01.xml https://sturm-edition.de/api/files/Q.01.19150918.FMA.01.xml
curl -o Q.01.19150827.FMA.01.xml https://sturm-edition.de/api/files/Q.01.19150827.FMA.01.xml
curl -o Q.01.19150303.FMA.01.xml https://sturm-edition.de/api/files/Q.01.19150303.FMA.01.xml
...

```

cat briefe_marc.xml (Mac/Linux)/-Path "briefe_marc.xml" (Windows) gibt den Inhalt der Datei ins Terminal; grep -o 'Q.*FMA.01.xml\b' (Mac/Linux) bzw. Select-String -Pattern 'Q.*FMA.*\.xml\b' (Windows) findet in diesem Inhalt alle Zeichenketten zwischen “Q” und “FMA.01.xml”, wobei nach “xml” durch das Hinzufügen von \b das Zeichenende angezeigt ist; die 45 gefundenen Zeichenketten werden in je eine neue Zeile geschrieben, wobei mit curl -o \$_ der Befehl curl -o und mit \$_ (Mac/Linux) bzw. \$match (Windows) als Platzhalter die Zeichenkette (also der Dateiname) geschrieben wird, gefolgt von https://sturm-edition.de/api/files/\$_ (Mac/Linux) bzw. https://sturm-edition.de/api/files/\$match und mit \$_ bzw. \$match wieder die Zeichenkette (also wieder der Dateiname). Mit einem dritten Kommando, bash, führen wir die erstellte Datei aus, d.h. die in ihr stehenden Kommandos werden ausgeführt – also via curl (**C**lient **U**RL) die Briefe heruntergeladen.

```
bash dateinamen_briefe_marc.txt
```

Egal, wie Sie die Dateien heruntergeladen haben, sollten Sie 45 Briefe im xml-Format vorfinden. Öffnen Sie dann das Terminal (Mac/Linux) bzw. die PowerShell (Windows) und bewegen sich mit cd, also **change directory**, in den Ordner (directory), in dem Ihre Textdateien liegen. In meinem Fall ist das unter Documents/GitHub/digital_history_intro/docs/letters_Der_Sturm.

```
(base) serina00@dg-19-mac-02 ~ % cd Documents/GitHub/digital_history_intro/docs/letters_Der_Sturm
```

Bei den meisten von Ihnen ist das vermutlich unter “Downloads” – probieren Sie es aus.

(Um zu prüfen, was in einem Ordner liegt, können Sie im Terminal ls (für list) eingeben, bzw. in der PowerShell dir (für directory)):

```
ls
```

```
Q.01.19140115.FMA.01.xml    Q.01.19150315.FMA.02.xml
Q.01.19140119.FMA.01.xml    Q.01.19150327.FMA.01.xml
Q.01.19140121.FMA.01.xml    Q.01.19150417.FMA.01.xml
Q.01.19140124.FMA.01.xml    Q.01.19150501.FMA.01.xml
Q.01.19140125.FMA.01.xml    Q.01.19150615.FMA.01.xml
Q.01.19140125.FMA.02.xml    Q.01.19150703.FMA.01.xml
Q.01.19140409.FMA.01.xml    Q.01.19150710.FMA.01.xml
Q.01.19140414.FMA.01.xml    Q.01.19140421.FMA.01.xml
Q.01.19150827.FMA.01.xml    Q.01.19140507.FMA.01.xml
...
```

8.3 First Steps

Wenn Sie in den Ordner navigiert sind, in dem die Briefdateien liegen, können Sie mit einem einzeiligen Kommando die Suchvorgänge nach einer Grußformel, die Sie in einem Texteditor nacheinander mit **Strg-F** mit jeder einzelnen Datei ausführen würden, im Terminal/in der PowerShell mit dem Programm **grep** (Global Regular Expression Print, Mac/Linux) bzw. **Select.String** (Windows) für alle Briefe in diesem Ordner auf einmal vornehmen, indem Sie alle Dateien, die auf “.xml” enden, in die Suche aufnehmen. Die Ergebnisse – bei dieser Suche nach den Grußformeln “Mit herzlichem Gruß” oder “Mit herzlichen Grüßen” ein Treffer in einem Brief – können Sie sich im Terminal/in der PowerShell anschauen:

Mac/Linux:

```
grep -E -i '(Mit herzlichem Gruß|Mit herzlichen Grüßen)' *.xml
```

Windows:

```
Select-String -Path *.xml -Pattern "(Mit herzlichem Gruß|Mit herzlichen Grüßen)"
```

Output:

```
Q.01.19160115.FMA.01.xml:      <salute>Mit herzlichen Grüßen für Sie beide</salute>
```

Die Formulierung “Mit herzlichen Grüßen” kommt also einmal im Korpus vor, und zwar im Dokument Q.01.19160115.FMA.01.xml.

Sie können auch mit `wc -l` (Mac/Linux) den **Wordcount**, die Anzahl der gefundenen Treffer auf Zeilenebene, `-l` zählen, bzw. mit `Matches.Count` (Windows), und mit `>` in eine neue Datei schreiben (die während der Ausführung des Kommandos erstellt wird):

Mac/Linux:

```
grep -E -i '(Mit herzlichem Gruß|Mit herzlichen Grüßen)' *.xml | wc -l > count_greetings.txt
```

Windows:

```
(Select-String -Path *.xml -Pattern "(Mit herzlichem Gruß|Mit herzlichen Grüßen)").Matches.Count
```

Wenn Sie die neu erstellte Datei `count_greetings.txt` öffnen, die sich im selben Ordner wie die Briefe befindet, sollte dort “1” stehen, weil unsere Suche einen Treffer ergeben hat.

Das Kommando `grep` (Mac/Linux) hat im obigen Befehl den Zusatzparameter `E` bekommen, das Kommando `Select.String` (Windows) den Parameter `-Pattern`, d.h. wir suchen nicht eine exakte Zeichenkette, sondern nutzen Möglichkeiten zur Mustersuche, zur Suche nach Patterns. Diese werden formuliert als sog. **Extended Regular Expressions** (von hier kommt das `E`), als [reguläre Ausdrücke](#). Wir haben in unserer Suchabfrage nämlich nicht nur nach “Mit herzlichem Gruß” gesucht, sondern auch nach “Mit herzlichen Grüßen”, formuliert mit dem Zeichen “|”, hier als “oder” zu lesen. Mithilfe Regular Expressions können wir unsere Suche weiter ausbauen und nach verschiedenen Varianten/Schreibweisen auf einmal suchen.

Note

Regular Expressions haben verschiedene *flavours* – je nach Programmiersprache werden Dinge etwas anders formuliert, und manche Defaulteinstellungen unterscheiden sich. In unserem Fall benötigt `grep` noch den Parameter `-i`, um Groß- und Kleinschreibung zu ignorieren. `Select.String` ignoriert dies by default und braucht keinen zusätzlichen Parameter. Solche Feinheiten sind bei der Arbeit mit Regular Expressions wichtig zu wissen, aber das lernt man on the go.

Mac/Linux:

```
grep -E -i '(Mit herzlichem Gru(ß|ss)|Mit herzlichen Grü(ß|ss)en|H(e|.)?rzl. Gru(ß|ss))' *.xml
```

Windows:

```
(Select-String -Path *.xml -Pattern "(Mit herzlichem Gru(ß|ss)|Mit herzlichen Grü(ß|ss)en|H(
```

So formuliert finden wir 17 Treffer für eine Grußformel, mit den möglichen Schreibweisen “Mit herzlichem Gruß”, “Mit herzlichem Gruss”, “Mit herzlichen Grüßen”, “Mit herzlichen Grüssen”, “Herzl. Gruß”, “Herzl. Gruss”, “Hrzl. Gruß”, “Hrzl. Gruss”.

Wenn wir herausfinden möchten, ob Grüße mal *herzlich*, mal *hrzl.* oder *freundlich* verschickt wurden, können wir die Suche und die Art der Ausgabe modifizieren:

Mac/Linux:

```
grep -E -i 'Gr(u|ü)(ß|ss)' *.xml
```

Windows:

```
Select-String -Path *.xml -Pattern "Gr(u|ü)(ß|ss)"
```

Output:

```
Q.01.19140115.FMA.01.xml:      stets sofort antworte; es muß verloren gegangen
Q.01.19140119.FMA.01.xml:      <salute>Hrzl. Gruß</salute> <signed>Ihr <persName
Q.01.19140125.FMA.02.xml:      <salute>Hrzl. Gruß</salute>
Q.01.19140421.FMA.01.xml:      <closer>Gute Besserung <persName key="P.000
Q.01.19140507.FMA.01.xml:      <salute>besten Gruß</salute>
Q.01.19140831.FMA.01.xml:      <salute>Hrzl. Gruß von Eurem Freund in Waffen</
Q.01.19141113.FMA.01.xml:      <salute>Hrzl. Gruß 1 x 2</salute> <signed>Ihr <
Q.01.19150112.FMA.01.xml:      <salute>Hrzl. Gruß Ihnen beiden</salute>
Q.01.19150116.FMA.01.xml:      <salute>Mit herzl. Gruß Ihnen beiden</salute> <
Q.01.19150121.FMA.01.xml:      <salute>Herzl. Gruß</salute> <signed>Ihr <persName
...
```

Mit diesem Kommando durchsuchen wir also den Text nach dem Muster `Gr(u|ü)(ß|ss)`, also Beginn mit `Gr` oder `gr`, dann folgt entweder ein `u` oder ein `ü`, dann entweder ein `ß` oder `ss`. Weil wir kein Wortende markiert haben (das ginge mit `\b`), werden auch “Grüße” oder “Grüssen” gefunden.

Wenn Sie sich während der Lektüre des vorangegangenen Kapitels auf der Webseite durch die Briefe geklickt haben, werden Sie festgestellt haben, dass ein Brief nicht immer mit “Gruß” oder “Grüßen” endet. Beim Output der Suchanfragen im Terminal sehen Sie, dass alle Grußformeln von einem Tag-Paar umgeben sind: `<salute>` kennzeichnet den Beginn des Grußes, `</salute>` das Ende. Öffnen Sie eine der Briefdateien und suchen Sie nach “salute”. (Wenn Sie keinen XML-fähigen Editor auf dem Computer haben, öffnen Sie die Datei einfach mit einem Browser.)

```

112 ▾      <opener>
113          <salute>Lieber <persName key="P.0000001" ref="http://d-
            nb.info/gnd/118770950">Walden</persName>,</salute>
114      </opener>
115 ▾      <p>ich vermute, daß <persName key="P.0000058" ref="http://d-
            nb.info/gnd/118870645">Cassirer</persName> es auf den Proceß ankommen läßt; ich
            rate nicht dazu;
116          Sie wi<hi rend="underline">sse</hi>n ja meine Bedingung, daß ich auf gar
            keinen
117          Fall irgend welche Kosten von der Sache haben möchte. Das ist mir weder
118          <persName key="P.0000058" ref="http://d-
            nb.info/gnd/118870645">Cassirer</persName> noch <term type="journal"
            key="W.0000070" ref="http://d-nb.info/gnd/4127687-5">die
119          Aktion</term> wert.</p>
120      <p>Von <persName key="P.0000057" ref="http://d-
            nb.info/gnd/143669230">Reiche</persName> resp. <persName key="P.0000059"
            ref="http://d-nb.info/gnd/2097840-6">Arnold</persName> hab ich illustr. Katalog
            erhalten; Sie werden ihn wohl
121          auch inzwischen gesehen haben; sonst kann ich Ihnen den meinen schicken.</p>
122 ▾      <p>Von
123          <persName key="P.0000033" ref="http://d-
            nb.info/gnd/118969161">Filla</persName> hab ich die <term type="artwork"
            key="W.0000011">
124              <hi rend="underline">Häringe</hi>
125          </term> gewählt, von
126          <persName key="P.0000060" ref="P.0000060">Beneé</persName> ein größeres
            Aquarell, ich glaube mit blau (hell,
127          geometrisch) kein, hochformat.<pb xml:id="S.178v.02" n="178v"
            facs="http://resolver.staatsbibliothek-berlin.de/SBB0000DAA400000001"/> Auf
            beide Bilder haben sie
128          auf der Rückseite mit Blei „Marc“ geschrieben. Sie werden es schon finden.
129          Sobald ich die Sachen habe, sende ich 2 Aquarelle; geben Sie mir bitte die
            Adressen.</p>
130      </p>
131 ▾      <closer>
132          <salute>Hrzl. Gruß</salute> <signed>Ihr <persName key="P.0000003"
            ref="http://d-nb.info/gnd/11857745X">F. Marc</persName>
133          </signed>
134      </closer>

```

Figure 8.2: Ausschnitt aus Brief Nr. 1 von Franz Marc an Herwarth Walden

Wie Sie sehen, gibt es das Tag-Paar `<salute>-</salute>` zweimal, einmal umrahmt vom Tag-Paar `<opener>-</opener>`, einmal von `<closer>-</closer>`. Die Anrede ist mit dem ersten, die Grußformel mit dem zweiten Tag-Paar markiert. Wir können also, wenn wir mit Dokumenten arbeiten, die nach festgelegten Richtlinien ausgezeichnet wurden, nach dem Element Grußformel suchen, ohne erst einen Blick in die Texte werfen zu müssen, um verschiedene Suchabfragen zu formulieren. Wir formulieren unsere Suchabfrage um und suchen nun nach einer Abfolge von Zeichen mit dem Beginn `<closer>`, gefolgt von keinem bis zu beliebig vielen (.*) Zeichen der Klasse `cntrl`, also nicht sichtbare Zeichen wie Tabs, Seiten- oder Zeilenumbruch. Danach folgt `<salute>`, wiederum gefolgt von keinem bis zu beliebig vielen (.*) Zeichen, keinem bis zu beliebig vielen (.*) Zeichen der Klasse `cntrl` und nochmal keinem bis zu beliebig vielen (.*) Zeichen, bis der Beginn des Schlusstags zu `</salute>` kommt. Damit werden die verschiedenen Fälle in den Briefen abgedeckt, dass zwischen `<closer>` und `<salute>` Text oder ein Zeilenumbruch stehen kann oder auch nicht, und dass zwischen `<salute>` und `</salute>` Text, kein Text oder ein Zeilenumbruch kommen kann.

Mac/Linux:

```
grep -E -zo '<closer>[:cntrl:]*<salute>.*[:cntrl:]*<' *.xml
```

Output:

```
Q.01.19140115.FMA.01.xml:<closer>
    <salute>Hrzl.<
Q.01.19140119.FMA.01.xml:<closer>
    <salute>Hrzl. Gruß</salute> <signed>Ihr <persName key="P.0000003" ref="http://
Q.01.19140121.FMA.01.xml:<closer>
    <salute>Hrzl.</salute> <signed>Ihr <persName key="P.0000003" ref="http://
Q.01.19140125.FMA.02.xml:<closer>
    <salute>Hrzl. Gruß<
Q.01.19140409.FMA.01.xml:<closer>
    <salute>Herzl.<
Q.01.19140414.FMA.01.xml:<closer>
    <salute>Hrzl.</salute> <signed>Ihr <persName key="P.0000003" ref="http://
Q.01.19140507.FMA.01.xml:<closer>
    <salute>besten Gruß<
Q.01.19140512.FMA.01.xml:<closer>
    <salute>Hrzl.</salute> <signed>Ihr <persName key="P.0000003" ref="http://
Q.01.19140606.FMA.01.xml:<closer>
    <salute>Hrzl.</salute> <signed>Ihr <persName key="P.0000003" ref="http://
Q.01.19140608.FMA.01.xml:<closer>
    <salute>hrzl.</salute> <signed>Ihr <persName key="P.0000003" ref="http://
...
```

Wenn wir die Ergebnisse direkt in eine Datei schreiben wollen, können wir das natürlich auch tun:

Mac/Linux:

```
grep -E -zo '<closer>[:cntrl:]*<salute>.*[:cntrl:]*<' *.xml > Grussformeln.txt
```

Spätestens jetzt wäre es aber an der Zeit, das Instrumentarium zu wechseln: Mit dem Terminal bzw. der Shell kann man verschiedenste Operationen durchführen, und es gibt zahlreiche kleine Programme, die man zusätzlich installieren kann – zum Parsen, also Zerlegen von XML-Dateien, zur Bearbeitung von Bilddateien oder zum Download von YouTube-Videos. Die Übersichtlichkeit ist allerdings recht begrenzt, und gerade für die Analyse von Struktur- und Textdaten gibt es weitaus geeignetere Programmiersprachen wie R oder Python, wie in **?@sec-digitaletools** bereits erwähnt.

Um beispielsweise mit dem Volltext der Briefe weiterzuarbeiten, sei es für ein *close reading* oder für quantitative Textanalysen, können für eine bessere Lesbarkeit und einfachere Auswertungen die Auszeichnungen des TEI-XML entfernt werden.

9 Perspectives

Wenn Sie die von Ihnen erstellten Strukturierungen von Brief Nr. 8 von Franz Marc an Herwarth Walden und die identifizierten Entitäten mit denjenigen in den XML-Dateien der STURM-Editor:innen vergleichen, ergeben sich vermutlich einige Unterschiede. Ein zentraler ist sicher, dass sich die Herausgeber:innen bei ihrer Strukturierung an ein Schema gehalten haben, das im Bereich der Texteditionen Standard ist, [TEI XML](#), und das kann zahlreiche Vorteile haben. So können Sie beispielsweise die im vorherigen Kapitel gezeigten Abfragen nach der Grußformel durchführen, ohne sich Gedanken darüber machen zu müssen, ob sich die Benennung des Tags auf halber Strecke ändert. Und wenn Sie sich während der Forschungsarbeit dafür entscheiden würden, anstatt Grußformeln besser die Anrede zu untersuchen, oder aber das Korpus auf die Briefe von [Jacoba van Heemskerck](#) auszuweiten, könnten wir dies mit wenigen Änderungen in unseren Abfragen machen, weil auch die Anrede mit einem einheitlichen Tag codiert ist; würden wir die Quellen nur über die Webseite lesen und unsere Auszählungen von Hand machen, würde unsere Arbeit mit dem Hinzufügen neuer Dokumente von vorne beginnen.

Das Erstellen von standardisierten Daten mithilfe eines Schemas bzw. bestimmter Richtlinien ermöglicht es auch, verschiedene Datensätze miteinander zu kombinieren oder mit weiteren Daten anzureichern. Bei einem Blick in die Briefe, auf der Webseite oder in der XML-Datei, wird ersichtlich, dass Entitäten wie Personen oder Orte nicht nur als solche markiert und projektintern verlinkt, sondern auch mit weiteren Normdaten verbunden wurden, beispielsweise mit dem dazugehörigen Eintrag in der [GND](#), der Gemeinsamen Normdatei der Deutschen Nationalbibliothek, oder in [Geonames](#), einer Datenbank für geographische Daten.

```

112 <opener>
113 <salute>Lieber <persName key="P.0000001" ref="http://d-
nb.info/gnd/118770950">Walden</persName>,</salute>
114 </opener>
115 <p>ich habe nicht das geringste vom Anwalt erhalten; Sie kennen mich ja, daß ich
116 stets sofort antworte; es muß verloren gegangen sein. Grüßen Sie bitte D<hi rend="super">
117 <hi rend="underline">r</hi>
118 </hi>
119 <persName key="P.0000056" ref="P.0000056">Feige</persName> und sagen Sie ihm
120 das.</p>
121 <p>In einer niederrheinischen Zeitung soll von einer bevorstehenden großen
122 Ausstellung in <placeName key="0.0000045"
ref="http://sws.geonames.org/2952539">Barmen</placeName> von <persName key="P.0000009"
ref="http://d-nb.info/gnd/118559737">Kandinsky</persName> mir u.s.w.
123 berichtet worden sein; ich kann mir nur denken, daß die <persName key="P.0000057"
ref="http://d-nb.info/gnd/143669230">Reiche</persName>-<placeName key="0.0000032"
ref="http://sws.geonames.org/2935022">Dresden</placeName> Collection dahin
124 kommt;<pb xml:id="S.177v.02" n="177v" facs="http://resolver.staatsbibliothek-
berlin.de/SBB0000DAA300000001"/> ich
125 bin natürlich einverstanden, nur soll die frei<hi rend="underline">e
126 Rück</hi>fracht <placeName key="0.0000045"
ref="http://sws.geonames.org/2952539">Barmen</placeName> - <placeName key="0.0000002"
ref="http://sws.geonames.org/2950159">Berlin</placeName> gesichert
127 sein.<note>Im Jahr 1913 fand in der Stadt Barmen eine STURM-Ausstellung mit
128 Werken der Künstlergruppe „Der Blaue Reiter“ statt. In der Literatur gilt
129 diese Ausstellung als nicht ausreichend nachgewiesen; dieser Brief gibt
130 endgültigen Aufschluss über das tatsächliche Stattfinden der Ausstellung.
131 Vgl. Enders, Rainer: Ausstellungen außerhalb der Berliner Galerie. URL: <ref
target="https://www.arthistoricum.net/themen/portale/sturm/ausstellungen/">https://www.ar
thistoricum.net/themen/portale/sturm/ausstellungen/</ref>
132 (Aufruf 06.04.2017).</note> Aber es ist natürlich nur Vermutung von mir. Von
133 <persName key="P.0000057" ref="http://d-nb.info/gnd/143669230">Reiche</persName> höre ich
gar nichts.</p>
134 <closer>
135 <salute>Hrzl.</salute>
136 <signed>Ihr <persName key="P.0000003" ref="http://d-nb.info/gnd/11857745X">F.
137 Marc</persName>
138 </signed>
139 </closer>

```

Figure 9.1: Ausschnitt aus Brief Nr. 1 von Franz Marc an Herwarth Walden, Normdaten gelb hervorgehoben.

Wenn Sie den Link zu [Kandinski](#) oder zu [Berlin](#) anklicken, erhalten Sie auf den Seiten der GND bzw. Geonames zahlreiche zusätzliche Informationen zur Person bzw. zum Ort, unter anderem Lebensdaten bzw. Geokoordinaten. Wenn Sie nun beispielsweise wissen wollten, welche Orte in den Briefen Franz Marcs genannt werden, könnten Sie diese nicht nur mithilfe des Tag-Paars `<placeName>-</placeName>` extrahieren, sondern mit den dazugehörigen Geokoordinaten anreichern und sich auf einer Karte anzeigen lassen.




Figure 9.2: Orte, die im Briefkorpus von Franz Marc an Herwarth Walden genannt werden (Visualisierung erstellt mit Palladio).




Figure 9.3: Orte, die im Briefkorpus von Franz Marc an Herwarth Walden genannt werden, Detail (Visualisierung erstellt mit Palladio).

Für solche Vorgänge reicht ein kurzes (aber nicht unbedingt schnell erstelltes ...) [Skript](#), an

das sich, je nach Ziel bzw. gewünschter Visualisierung, noch weitere Schritte zur Datenverfeinerung bzw. -anreicherung anschließen lassen.¹ Diese Abfolge lässt sich recht unaufwendig auf weitere Dokumente ausweiten – ob Sie nur die Orte in den Briefen Franz Marcs oder auch in denen Jacoba van Heemskercks extrahieren und visualisieren wollen, spielt mit Blick auf die Rechenzeit des Skripts keine Rolle.

Das Erstellen von Datensätzen nach bestimmten Richtlinien, einerseits formal, andererseits auch mit Blick auf die [FAIR-Prinzipien](#), bietet also viele Vorteile für die eigene Arbeit – so müssen beispielsweise Schemata zur Klassifizierung nicht von Neuem erfunden werden – ebenso wie für die Arbeit anderer – grundlegende Informationen können übernommen werden und es bleibt mehr Zeit für die inhaltliche Forschung.

Ein anschauliches Beispiel für die Weiternutzung von Daten ist das von Studierenden erstellte Projekt [quoteSalute](#), eine Webseite, auf der Sie historische Grußformeln generieren lassen können, falls Ihnen beim Briefeschreiben der Standardgruß zu langweilig geworden ist. Das Projekt hat hierfür mehrere XML-codierte Briefkorpora, die alle als offen nutzbare Daten online verfügbar sind, kombiniert, die Grußformeln extrahiert und angereichert. Die genaue Projektbeschreibung finden Sie [hier](#).

Neuer Gruß quote me!

»Also, auf baldiges enormes Wiederseh'n. Herzlichst der Deinige.«

➔ [Hermann Bahr – Arthur Schnitzler: Briefwechsel, Aufzeichnungen, Dokumente 1891–1931](#)
Adele Sandrock an Hermann Bahr, 17. 8. 1894
CC BY 4.0

Grußformeln filtern

Von	An	Form	Sprache
☐ ♀ Weiblich	☐ ♀ Weiblich	☐ 📧 Formal	☐ Deutsch
☐ ♂ Männlich	☐ ♂ Männlich	☐ ❤ Informal	☐ Englisch
☐ ○ Neutral	☐ ○ Neutral		☐ Spanisch
			☐ Italienisch
			☐ Französisch
			☐ Griechisch
			☐ Latein

✓ Filter anwenden 🗑 Filter aufheben

Schöner Grüßen
Auf dieser Webseite können Sie nach historischen Grußformeln stöbern. Haben Sie die passende Grußformel gefunden, können Sie sie mit dem "quote me!"-Button ganz einfach kopieren. Öffnen Sie das E-Mail-Programm Ihrer Wahl und dann einfach in die nächste Mail einfügen und versenden! Wenn Ihnen die angezeigte Grußformel nicht gefällt, generieren Sie sich einfach mit Klick auf "Neuer Gruß" eine andere. Mit Filtern können Sie die Suchanfrage außerdem nach Ihren Wünschen einschränken.

Mitmachen
Die Grußformeln Ihrer digitalen Briefedition sollen bei quoteSalute dabei sein? Gerne! Mehr Informationen finden Sie in der [Dokumentation](#).

Figure 9.4: Startseite von quoteSalute

¹In diesem Fall wurde die mithilfe des verlinkten Skripts (in der Programmiersprache R) erstellte [csv-Datei](#) mit OpenRefine [weiter bearbeitet](#), um den Adressen Geokoordinaten hinzuzufügen. Die so [angereicherte Tabelle](#) wurde in das Onlinetool [Palladio](#) geladen, das Koordinaten auf einer Karte darstellen kann.

Wie Sie sehen, können Sie sich Grüße nicht nur generieren lassen, sondern auch filtern, beispielsweise nach Geschlecht der Absender:innen bzw. der Adressat:innen oder nach Sprache. Sie können dies deswegen, weil die vorhandenen Codierungen der Textdateien im Projekt ausgeweitet und zum Beispiel um das Geschlecht der beteiligten Personen, sofern ersichtlich, ergänzt wurden. Der Code für das Projekt ist dabei offen auf einem [GitHub-Repositorium](#) zugänglich, und neue Korpora werden gerne aufgenommen.

Computergestütztes und computerbasiertes Arbeiten, das sollte dieser Guide vermitteln, vereinfacht, beschleunigt oder ermöglicht gar Prozesse, die wir für unsere historische Forschung nutzen können. Dabei gibt es mittlerweile zahlreiche Programme, die über eine graphische Oberfläche bedient werden können und die meisten Anforderungen aus geisteswissenschaftlicher Sicht erfüllen. Manche Analysen hingegen erfordern sehr spezifische Schritte oder viel Rechenkapazitäten, für die sich das Erlernen einer Programmiersprache lohnen kann. Gemeinsam ist beidem, dass es sowohl für das Formulieren einer interessanten Fragestellung, für die Auswahl der Datenbasis als auch für die Interpretation der Ergebnisse, die die Maschine liefert, informierte Expertise braucht – ein Programm zur Bestimmung der Autor:innenschaft eines unbekannten Textes rechnet unendlich lange, wenn es alle existierenden Texte mit einem unbekannten vergleichen muss; hier braucht es eine Eingrenzung auf eine Auswahl durch Literaturwissenschaftler:innen. Historische Forschung ist immer auch Analyse des Einzelfalls, des Partikularen, eines *close readings*; die Möglichkeit, den Blick mithilfe des Computers auszuweiten, kann in den meisten Fällen gewinnbringend in Betracht gezogen werden.

A Glossary

Glossary

- **API: Application Programming Interface:** a facility offered by a web resource which allows search queries independent of a **GUI**, often performed using scripts
- **bash:** default program that runs in the **command line**
- **big data:** huge amount of data, identifiable through repeated freezing of your standard program when opening a file
- **born digital data:** data which originated in a digital form
- **CLI: Command Line Interface,** text interface that allows interaction with the computer; see also **bash**
- **CMS: Content Management System**
- **Console:** See **CLI**
- **Crowdsourcing:** projects that include the active participation of the public to generate content, transcribe sources etc.
- **csv: comma separated values,** a structured text format, using commas as separators between columns
- **distant reading:** quantitative approach to huge amounts of texts, using computational methods to search for interpretable patterns
- **GUI: Graphical User Interface**
- **HTML: Hypertext Markup Language,** a structured text format, like the format this guide is written in, to render documents in a browser
- **Jupyter notebook:** web application/interactive coding environment that runs in a browser; let's you create and share code (<https://jupyter.org>)
- **machine readable:** transformation of, for example, text into a data format that is processable by a computer
- **OCR: Optical Character Recognition,** process of transforming text on an image into a data format
- **OS: Operating System**
- **OSS: Open Source Software**
- **Regular Expression:** syntax for search and replace text using patterns (instead of exact matches)
- **terminal:** See **CLI**

B Literature, Tools, Tutorials

B.1 What is digital history?

- Antenhofer, Christina, Kühberger, Christoph, Strohmeier, Arno (Hrsg.): Digital Humanities in den Geschichtswissenschaften. Wien 2023.
- Brennan, Sheila A.: Digital History, in: The Inclusive Historian's Handbook, <https://inclusivehistorian.com/digital-history/>, 04.06.2019.
- Hohls, Rüdiger: Digital Humanities und digitale Geschichtswissenschaften, in: Busse, Laura u. a. (Hg.): Clio-Guide. Ein Handbuch zu digitalen Ressourcen für die Geschichtswissenschaften, Berlin 2018, S. A.1-1–B.1-34. Online: <https://doi.org/10.18452/19244>.
- Romein, C. Annemieke u. a.: State of the Field: Digital History, in: History 105 (365), 04.2020, S. 291—312. Online: <https://doi.org/10.1111/1468-229X.12969>.
- Winters, Jane: Digital History, in: Tamm, Marek; Burke, Peter (Hg.): Debating New Approaches to History, London 2019, S. 277–300.
- Art. “Digital history”, in: Wikipedia, 07.09.2022. Online: https://en.wikipedia.org/w/index.php?title=Digital_history&oldid=1220662831, Stand: 25.04.2024.

B.2 Introductions and Guides

- Battershill, Claire; Ross, Shawna: Using Digital Humanities in the Classroom. A Practical Introduction for Teachers, Lecturers, and Students, London u.a. 2022.
- Blaney, Jonathan u. a.: Doing Digital History. A Beginner's Guide to Working with Text as Data, Manchester 2021.
- Cohen, Daniel J.; Rosenzweig, Roy: Digital History. A Guide to Gathering, Preserving, and Presenting the Past on the Web, Philadelphia 2006. Online: <https://chnm.gmu.edu/digitalhistory/>.
- Döring, Karoline u. a. (Hg.): Digital History. Konzepte, Methoden und Kritiken Digitaler Geschichtswissenschaft, Boston 2022, Online: <https://doi.org/10.1515/9783110757101>.

- Dougherty, Jack; Nawrotzki, Kristen (Hg.): Writing History in the Digital Age, 2013. Online: <https://doi.org/10.3998/dh.12230987.0001.001>.
- Graham, Shawn u. a.: Exploring Big Historical Data. The Historian's Macroscope, 2022. Online: <https://doi.org/10.1142/12435>.
- Lemerrier, Claire; Zalc, Claire: Quantitative Methods in the Humanities. An Introduction, Charlottesville 2019.
- Peroni, Silvio: [The CTP Book](#). A book for teaching Computational Thinking and Programming skills to people with a background in the Humanities.

B.3 Digital History Tools (free/open source)

B.3.1 General

- Programming Historian: [Tutorials zu verschiedenen Tools und Methoden für historische Forschung und Lehre](#)

B.3.2 Data Analysis

- [Datasette](#): interaktives Tool zur Datenexploration und -visualisierung
- [Heurist](#): webbasierte Forschungsumgebung zur Datenerhebung, -exploration und -visualisierung
- [Nodegoat](#): webbasierte Forschungsumgebung zur Datenerhebung, -exploration und -visualisierung

B.3.3 Maps

- [Dariah GeoBrowser](#): webbasiertes Tool zur Darstellung raumzeitlicher Daten
- [QGis](#): Software zum Erstellen, Bearbeiten, Anzeigen und Analysieren räumlicher Information
- [Map in Seconds](#): webbasiertes Tool zur Erstellung von Karten (optimiert für Chrome Browser)
- [Palladio](#): webbasiertes Tool zur Visualisierung strukturierter Daten, u.a. Geodaten

B.3.4 Network Analysis

- [Gephi](#): Programm zur Analyse und Visualisierung von Graphen und Netzwerken
- [Nodegoat](#): webbasierte Forschungsumgebung zur Datenerhebung, -exploration und -visualisierung, u.a. auch Netzwerkanalyse
- [Palladio](#): webbasiertes Tool zur Visualisierung strukturierter Daten, u.a. auch Netzwerkanalyse

B.3.5 Text/Corpus Analysis

- AntConc: [Korpusanalyse-Toolkit](#)
- Lemmatisierung: [Sammlung der FID Romanistik](#)
- Natural Language Toolkit, Package für Python zur Tokenisierung, Lemmatisierung usw.: [NLTK](#)
- Tokenisierung: [Tutorial von fortext zu NLTK](#)
- Voyant-Tools: [Sammlung von Tools zur Textanalyse, browserbasiert oder standalone](#)

B.3.6 Storytelling

- [Omeka](#): webbasierte Plattform zur Kuration digitaler Sammlungen, für die Veröffentlichung und Ausstellung von Bildern/Objekten
- [StoryLine JS](#): Tool zur Erstellung von interaktiven Diagrammen
- [StoryMap JS](#): Tool zur Erstellung von interaktiven Karten/Bildern mit verschiedenen Elementen
- [Timeline JS](#): Tool zur Erstellung von interaktiven Timelines

B.3.7 Visualisation

- Bostock, Michael; Heer, Jeffrey; Ogievetsky, Vadim: A Tour through the Visualization Zoo. A Survey of Powerful Visualization Techniques, from the Obvious to the Obscure, in: Queue 8, Nr. 5 (2010). Online: <https://queue.acm.org/detail.cfm?id=1805128>
- [Data Visualisation Catalogue](#): Guide zur Auswahl von Visualisierungsformen
- [Datasette](#): interaktives Tool zur Datenexploration und -visualisierung
- FID Romanistik: [Sammlung von Tools zur Datenvisualisierung](#)

- [Palladio](#): webbasiertes Tool zur Visualisierung strukturierter Daten
- [RAWGraphs](#): Tool zur Datenvisualisierung von tabularen Daten (.tsv-, .csv-, .dsv- oder .json-Dateien)

B.4 Digital Literacy, Digital Criticism

- Ekström, Andreas: The Moral Bias behind your Search Results, TED talk 7.12.2015 (9:18), Online: https://www.youtube.com/watch?v=_vBggxCNNno.
- Gibbs, Frederick W.: New Forms of History: Critiquing Data and Its Representations, in: The American Historian, February 2016. Online: <http://tah.oah.org/february-2016/new-forms-of-history-critiquing-data-and-its-representations/>.
- Tavani, Herman; Zimmer, Michael: Search Engines and Ethics, in: Edward N. Zalta (Hg.): The Stanford Encyclopedia of Philosophy (Fall 2020 Edition), Online: <https://plato.stanford.edu/archives/fall2020/entries/ethics-search/>, Kap. 3.1.

B.5 Programming Languages & Editors

- Python:
 - Althage, Melanie u. a.: Python für Historiker:innen. Ein anwendungsorientierter und interaktiver Einstieg, 20.07.2022, [Jupyter Book, \(v1.0\)](#)
 - Karsdorp, Folger: [Python Programming for the Humanities. Interactive Tutorial and Introduction to Programming with Python for the Humanities.](#)
 - Mattingly, William : [PythonHumanities.com. A Free Course for the Digital Humanities.](#)
 - Editor z.B. [PyCharm](#)
- R:
 - Mullen, Lincoln A.: [Computational Historical Thinking With Applications in R](#)
 - Phillips, Nathaniel D.: [YaRrr! The Pirate's Guide to R.](#)
 - Wickham, Hadley; Gromm, Garrett: [R for Data Science.](#)
 - Editor z.B. [RStudio](#)
- Editoren: [Anaconda](#); [Sublime Text](#); [Visual Studio Code](#)

B.6 Regular Expressions

- Knox, Doug: Understanding Regular Expressions, Programming Historian 2 (2013), <https://doi.org/10.46430/phen0033>. (self-learning lesson)
- RegexOne: [Learn Regular Expressions with simple, interactive exercises](#). (interactive self-learning tutorial)

B.7 Terminal/Command Line/Shell

- Dawson, Ted: Introduction to the Windows Command Line with PowerShell, Programming Historian 5 (2016), <https://doi.org/10.46430/phen0054>. (self-learning lesson)
- MIT Computer Science Department: [1-hour-lecture on the Shell](#) (video)
- Milligan, Ian; Baker, James: Introduction to the Bash Command Line, Programming Historian 3 (2014), <https://doi.org/10.46430/phen0037>. (self-learning lesson)
- datacamp course: [Introduction to Shell](#) (interactive self-learning lesson)
- Jeroen Janssens: [Data Science at the command line](#) (book)

B.8 XML

- Latex Ninja Blog: [A shamelessly short intro to XML for DH beginners \(includes TEI\)](#) (blog post)

References

- [1] Jonathan Blaney et al. *Doing digital history: a beginner's guide to working with text as data*. eng. IHR research guides. Manchester: Manchester University Press, 2021. ISBN: 978-1-5261-3268-0.
- [2] Stephanie Russo Carroll et al. “The CARE Principles for Indigenous Data Governance”. en. In: *Data Science Journal* 19 (Nov. 2020), p. 43. ISSN: 1683-1470. DOI: [10.5334/dsj-2020-043](https://doi.org/10.5334/dsj-2020-043). URL: <http://datascience.codata.org/articles/10.5334/dsj-2020-043/> (visited on 11/28/2022).
- [3] Catherine D’Ignazio and Lauren F. Klein. *Data feminism*. English. OCLC: 1157171756. 2020. ISBN: 978-0-262-35852-1. URL: <https://direct.mit.edu/books/book/4660/Data-Feminism>.
- [4] Marie-José Kolly and Simon Schmid. “Sie ist hübsch. Er ist stark. Er ist Lehrer. Sie ist Kindergärtnerin”. de. In: *Republik* (Apr. 2021). URL: <https://www.republik.ch/2021/04/19/sie-ist-huebsch-er-ist-stark-er-ist-lehrer-sie-ist-kindergaertnerin> (visited on 08/23/2022).
- [5] Emmanuel Le Roy Ladurie. “La fin des érudits”. In: *Le Nouvel Observateur* (Aug. 1968).
- [6] Claire Lemercier and Claire Zalc. *Quantitative Methods in the Humanities. An Introduction*. Charlottesville: University of Virginia Press, 2019. ISBN: 978-0-8139-4270-4.
- [7] Chantel Ridsdale et al. *Strategies and Best Practices for Data Literacy Education Knowledge Synthesis Report*. Jan. 2015. DOI: [10.13140/RG.2.1.1922.5044](https://doi.org/10.13140/RG.2.1.1922.5044).
- [8] Roopika Risam. “It’s Data, Not Reality”: On Situated Data With Jill Walker Rettberg. en. June 2020. URL: <https://medium.com/nightingale/its-data-not-reality-on-situated-data-with-jill-walker-rettberg-d27c71b0b451> (visited on 08/16/2022).
- [9] C. Annemieke Romein et al. “State of the Field: Digital History”. en. In: *History* 105.365 (Apr. 2020), pp. 291–312. ISSN: 0018-2648, 1468-229X. DOI: [10.1111/1468-229X.12969](https://doi.org/10.1111/1468-229X.12969). URL: <https://onlinelibrary.wiley.com/doi/10.1111/1468-229X.12969> (visited on 09/15/2022).
- [10] Mark D. Wilkinson et al. “The FAIR Guiding Principles for scientific data management and stewardship”. en. In: *Scientific Data* 3.1 (Mar. 2016). Number: 1 Publisher: Nature Publishing Group, p. 160018. ISSN: 2052-4463. DOI: [10.1038/sdata.2016.18](https://doi.org/10.1038/sdata.2016.18). URL: <https://www.nature.com/articles/sdata201618> (visited on 11/09/2022).